拡散単眼深度推定における選択的な境界鋭化

TODO 著者名
TODO 専攻・学科
TODO 大学
TODO 市, 国
TODO メールアドレス

***Abstract*—拡散モデルに基づく単眼深度推定は面の精度が高い一方、物体境界における深度の不連続を平滑化してしまう。分割モデルが描く輪郭で予測深度を鋭化するのは自然な対処だが、すべての輪郭に適用すると NYUv2 の境界精度はかえって低下する。本研究は測定により、その原因が輪郭の位置精度ではなく、大半の輪郭が深度段差を伴わないことにあり、そこへ鋭化を適用すると存在しない不連続を導入してしまう点にあることを示す。正解データを用いて正しい輪郭のみを選び、輪郭の位置を一切変えずに鋭化すると、効果の符号は反転する。この知見に基づき、鋭化操作を固定し、適用対象の輪郭のみを学習により選別する手法を提案する。NYUv2 において、提案手法は境界 BF_1 を seed 4 本で 11.9% 改善する。同じ選別器は再学習なしに、アーキテクチャも出力表現も異なる深度モデルへ適用でき、そちらでは 27.8% の改善を得た。学習を伴わない対照との比較から、学習の寄与は 10.7 ポイントと 17.4 ポイントと見積もられる。一方、データセット間では転移せず、試した対処では解消しなかったことも報告する。**

***Index Terms*—単眼深度推定, 深度境界, 後処理, 拡散モデル**

I. はじめに

事前学習済みの拡散モデルを転用した単眼深度推定 [1]–[3] は画素単位の精度では強いが、生成モデルの持つ滑らかさを物体境界で引き継いでしまう。AbsRel が優秀でありながら、画像中のすべての遮蔽境界が数画素にわたってにじんでいる、ということが起こりうる。画素平均の指標はこれを検出しない。境界画素は画像のごく一部で、平らな面に支配された指標は問題なしと報告するからである。境界専用の指標なら検出できる [5]。

深度モデルに手を入れずに済むため、境界を後処理で直す方針は魅力的である。先行研究は**深度をどう動かすか**を学習してきた [7]–[9]。本研究は逆の分解を取る。修正操作を固定し、それをどこに掛けるかだけを学習する。

この選択は経験的なものである。第 III-B 節では、分割モデル [11] が描いた輪郭すべてに鋭化を掛けると、Marigold V2 [3] の境界 BF_1 が 1.90% **下がる**ことを測定する。同じ測定が理由も示す。輪郭の位置はすでに十分であり、一方で輪郭の 79.8% は深度段差をまったく示していない。そこを鋭化しても滑らかな面を壊すだけである。位置を一切変えずに、正解データで正しい輪郭だけを選ぶと、効果は -1.90% から $+43.39\%$ へ動く。ボトルネックは位置精度ではなく選別である。

本研究の貢献は次の 4 点である。

1) 後処理による境界鋭化が失敗する原因を、輪郭の位置精度ではなく輪郭の選別にあることとして特定した（第 III-D 節）。
2) 修正操作を固定し、その適用対象のみを学習する手法を提案した。これにより学習の寄与の帰属が明確になる（第 III-E 節）。
3) 本手法が再学習なしに深度モデル間で転移する一方、データセット間では転移しないことを示した（第 IV 節、第 VI 節）。

第 VI 節では、本手法がデータセットをまたいでは転移しないこと、およびその修復を試みて失敗したことを報告する。

II. 関連研究

拡散ベースの単眼深度推定。Marigold [1] は Stable Diffusion を合成 RGB-D で微調整し、アフィン不変な単眼深度推定へ転用した。Marigold V2 [3] はその定式化を保ったまま、U-Net を、画像編集モデルから転用した 213 億パラメータの拡散トランスフォーマに置き換え、4 bit QLoRA で学習し、1 ステップで推論する。Lotus [2] は拡散のスケジュールを取り除き、タイムステップを固定して 1 ステップで予測する。その後、1 ステップ化が手法を単純化すると同時に桁違いに高速化することが示された [4]。本研究は、この系統の中で可能な限り離れた 2 つのモデルで評価する。一つは Marigold V2 [3]（21,282,180,672 パラメータの拡散トランスフォーマ、アフィン不変な log 深度を出力）、もう一つは Lotus [2]（8.68 億パラメータの UNet、視差を出力）である。

後処理としての境界鋭化。Ramamonjisoa らの研究 [7] が最も近い。遮蔽境界の周囲の画素を再標本化する 2 次元変位場を学習するもので、任意の深度推定器の出力に適用でき、NYUv2 の学習 795 枚・評価 654 枚という使い方まで本研究と同一である。SharpNet [8] は遮蔽輪郭の回復を深度ネットワーク自身の学習に組み込む。Edge-guided 後処理 [9] は自己教師ありの視差合成において境界を保存する。より最近では、NeRF による深度精緻化 [10] が、単眼推定と再構成された場を融合して幾何的な細部を回復している。これらはいずれも**深度をどう動かすか**を学習する。著者らの知る限り、修正操作を固定して対象だけを学習する研究はなく、またプロンプト可能な分割モデルを境界候補の供給源として用いる研究もない。

直接比較は行っていない。[7] は学習済み重みが公開されておらず、公開実装も現行の実行環境では動作しないため、本稿では直接比較を行わない。同一条件での再実装による比較は今後の課題とする。

境界指標。Depth Pro [5] のスケール不変な境界 BF_1 を採用する。隣接画素間の深度の**比**が閾値を超えたときに深度段差があると判定し、その閾値を掃引する指標である。本研究は新しい指標を提案しない。Lotus も Marigold V2 も NYUv2 の BF_1 を報告していないため、ベースラインは著者らが測定した。

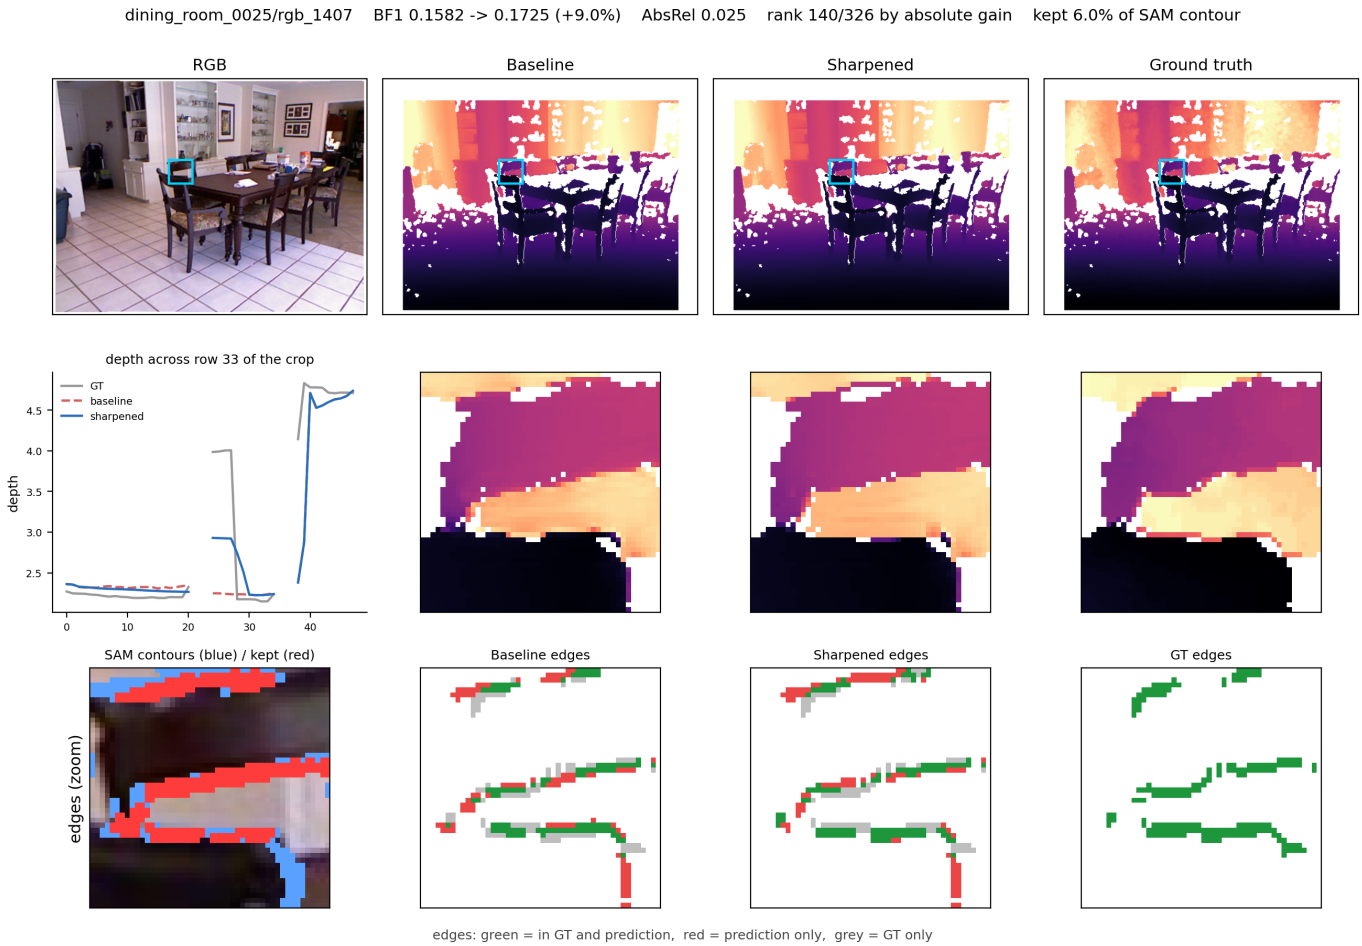


Fig. 1. 提案手法の動作例（ダイニングルームのフレーム）。上段は画像全体で、選別された輪郭の外側は変化しない。中段は椅子の背もたれの境界を 48 px で切り出したもので、左端にその断面の深度プロファイルを示す。ベースラインは正解が持つ 2 つの段差をいずれも捉えていないが、鋭化後は両方が再現されている。修正が書き換える帯は 2 画素幅であるため、中段の 3 枚は切り出し範囲から求めた共通のカラースケールで表示している。下段は各深度マップが含む不連続エッジで、これが BF_1 の比較対象である。緑は正解と予測の両方、赤は予測のみ、灰は正解のみ。このフレームは、AbsRel が評価集合の中央値 0.0303 以下である 326 枚を絶対利得で並べたときの 140 位であり、相対利得 $+9.01\%$ は評価集合の中央値 $+13.15\%$ に近い。正確な側の半分に限ったのは、破綻した予測を立て直す例ではなく良い予測を鋭化する例を示すためである。

深度のための領域分割。 Segment Anything [11] は、深度を事前情報としてマスクを精緻化する方向で利用されてきた。本研究はこれを逆方向に用いる。学習した選別器が選り分ける**深度境界の候補**の供給源としてである。

III. 手法

図 2 にパイプラインを示す。深度推定モデルと分割モデルは凍結する。修正は第 III-A 節の固定操作で、何も学習しない。学習する構成要素は選別器だけであり、それがなぜ必要かを示す測定が第 III-B 節である。

A. 修正操作

この操作を**障壁鋭化**と呼ぶ。選別された輪郭を、深度を内挿してはならない障壁として扱うためである。z を予測深度、V をその有効画素、$C \subseteq V$ を輪郭画素の集合とする。操作はまず帯

$$B = \{\, p \in V \mid \mathrm{dist}(p, C) \le r_b \,\}, \qquad r_b = 2 \tag{1}$$

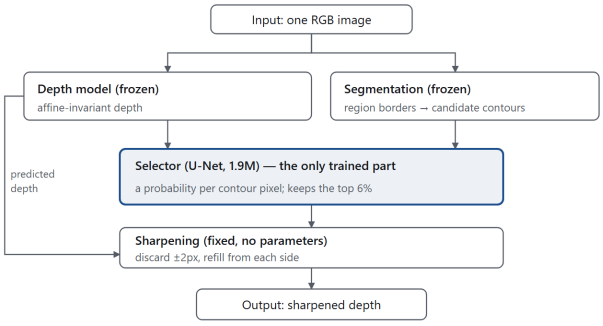


Fig. 2. 学習するのは選別器だけ。深度推定モデルも分割モデルも凍結し、修正操作はパラメータを持たない固定操作である。したがって利得は選別のみに帰属する。

を捨て、$V \setminus B$ の連結成分にラベルを付ける。これにより輪郭の両側は異なるラベルを持つ。次にラベルを 1 画素ず

TABLE I
MARIGOLD V2 で後処理による鋭化が失敗する理由と、何がそれを直すか。NYUv2 654 枚。オラクル選別は正解データを用いて分割輪郭の部分集合を選ぶもので、輪郭は 1 画素も動かさない。

鋭化した輪郭	残存率	BF_1 の変化
分割モデルの全輪郭	100%	−1.90%
オラクル選別（段差から 1 px 以内）	6.07%	+**43.39**%

つ内側へ伝播させて B を覆い、各 $p \in B$ にラベル $\ell(p)$ を与える。捨てた画素は自分の側からのみ埋め直す。

$$\hat{z}(p) = \frac{1}{|N(p)|} \sum_{q \in N(p)} z(q) \tag{2}$$

ここで $N(p) = \{\, q \notin B \mid \|q - p\| \le r_f,\ \ell(q) = \ell(p) \,\}$、$r_f = 3$ である。B の外側の画素は変化しない。帯を捨てるのは、拡散モデルが境界をまたいで値を内挿するためである。片側だけから埋め直すことで、この混ざりを除去する。成分ラベルは輪郭そのものから作るのであって、分割マスクからではない。この操作は設定値を 2 つ持つだけで、学習するものは何もない。$r_f > r_b$ である必要があり、さもなければ $N(p)$ が空になり、操作は深度マップを変更しない。

両側が分かれるのは、輪郭が閉じているか画像端に達している場合だけである。画像の内側で途切れる輪郭では、その先端を回り込んで有効領域がつながるため、そこでは帯の両側が同一の連結成分に属し、片側からの補間が成立しない。選別はこれが生じる箇所を増やす。輪郭画素の 6% を残すと、輪郭は全体の輪ではなく断片になるからである。いずれも修復を弱める性質であり、本稿のすべての数値にそのまま含まれている。

B. 全輪郭に掛けると失敗する

表 I は、Marigold V2 を土台に、Segment Anything が描く輪郭すべてにこの操作を掛けた結果である。境界 BF_1 は 1.90% 低下する。この診断は、境界がすでにある程度正しいモデルに固有である。Lotus では同じ無選別の鋭化が逆に 10.31% **改善**する（表 IV）。ベースライン BF_1 が 0.0693 と Marigold V2 の 0.0884 より低く、境界がもともと鈍いぶん、鋭化による改善の余地が大きく、劣化の影響が小さいためである。選別は前者で操作を安全にし、両者で大きく改善させる。

C. 位置精度は問題ではない

真の深度不連続それぞれから最寄りの輪郭までの距離を測ると、中央値 1.00 px、66.9% が 1 px 以内、76.9% が 2 px 以内である。輪郭は境界のある場所にある。問題は逆方向にあり、輪郭画素の 79.8% は、半径 8 画素の窓の中に深度段差を一つも持たない、壁紙の柄、床の目地、ポスターの縁である。そこへ鋭化を適用すると、平坦な領域に誤った不連続を導入することになる。

D. 正解で選別すると符号が反転する

上に出た 2 つの許容距離は同じ量の裏返しではないので、両方を明記する。79.8% は各輪郭画素を中心とする半径 8 画素の窓という緩い基準、以下の選別は 1 画素という厳しい基準である。1 枚あたり 22,167 画素ある分割輪郭 (有効画素の 10.6%) のうち、真の不連続から 1 px 以内にあるのは 1,345 画素、すなわち 6.07% である。それをちょうど残し、残した輪郭はすべて元の位置に置いたまま鋭化すると、効果は −1.90% から +43.39% へ動く（表 I）。この実験では輪郭の位置を変更しておらず、鋭化を適用する輪郭の集合のみが異なる。したがって性能低下の主因は輪郭の位置精度ではなく、適用対象の選別にあると考えられる。この結果に基づき、第 III-E 節では選別を学習によって行う。

E. 選別器

入力と出力。 選別器は 4 段の U-Net で、パラメータ数は 1,928,993 である。RGB 画像（3 チャネル）、予測深度（1）、輪郭マスク（1）を入力し、画素ごとに 1 つのロジットを出す。予測深度は画像ごとに標準化する。この手順を省くと、学習時と推論時で水準や尺度が食い違ってもエラーは生じず、最終的な指標だけが目立たない形で悪化する。log 深度ではなく視差 v を出すモデルに対しては、先に $-\log\max(v, 10^{-3})$ を適用する。視差は深度が小さいほど大きくなるためそのまま与えると符号の反転した信号を渡すことになり、またアフィン不変な視差は 0 以下にもなりうるので、下限でクリップする。これは深度について単調だが、log 深度のアフィン変換ではない。視差の未知のシフトは対数を通って非線形性として残り、画像ごとの標準化では落ちない。それでも選別器はそのまま適用しており、表 II の Lotus 列がこの近似の価値である。

残存率。 確率の閾値ではなく、画像ごとに上位 6% の輪郭画素を残す。予算を 6% としたのは、学習フレームにおける正例率がこの値だからである（輪郭画素の 6.066% が真の段差から 1 px 以内にある）。閾値を固定すると、場面に含まれる輪郭の量によって残す量が変わり、鋭化が使う予算がフレームごとに動いてしまう。

損失と学習。 選別器は各画素でロジット s_p を出力し、輪郭上にマスクした二値交差エントロピー

$$\mathcal{L} = -\frac{1}{|C|} \sum_{p \in C} \big[\, y_p \log \sigma(s_p) + (1 - y_p) \log(1 - \sigma(s_p)) \,\big] \tag{3}$$

で学習する。有効画素のうち輪郭でない 89% は、選別器に問うていない問題である。輪郭画素は、正解深度の不連続から 1 px 以内にあれば正例とする。ここで不連続とは深度比 10% 超の段差である。この閾値は test 集合ではなく検証集合で選んだ。学習 795 枚から外した 40 シーン・141 枚で BF_1 を測ると、10% が +12.74% で、15・20・25% の +8.66・+6.29・+5.28% を上回る。閾値を上げると正例が輪郭画素の 6.07% から 2.13% まで減り、固定の予算がほとんど負例に費やされるためである。本手法のハイパーパラメータは、閾値も残存率もすべて検証集合で決定した（第 IV-D 節の対照は例外で、その旨を同節に記す）。正解データはラベル生成にのみ用い、推論時には使用しない。NYUv2 の学習用 795 枚をシーン単位で分け、654 枚を学習、141 枚を検証に充てる。配備するチェックポイントは検証適合率が最良のエポックのもので、見ているのはこの 654 枚だけであり、評価用の 654 枚とは別の集合である。学習は RTX 4090 1 枚で 16 分・VRAM 3.5 GB を要し、評価集合には一度も触れない。

TABLE II
主結果。SEED 4 本、± は標準偏差。同じ 4 つの選別器を両モデルに適用しており、学習は第一のモデルでのみ行った。絶対値では BF_1 が 0.0884 から 0.0989 へ、0.0693 から 0.0886 へ変化する。

土台の深度モデル	BF_1	選別なし	＋選別器
Marigold V2・213 億・log	0.0884	−1.90%	+**11.92** ± **0.90**%
Lotus・8.68 億・視差	0.0693	+10.31%	+**27.83** ± **1.27**%

IV. 実験

A. 設定

NYUv2 [12] の評価用 654 枚で評価する。学習フレームとはシーンが重複しない。第 VI 節の転移先は、[3] が用いる ScanNet [13] の検証用 800 枚と、Hypersim [14] のシーン単位ホールドアウト 300 枚である。いずれも深度を 16 bit ミリメートルで保持し、各データセット固有の有効マスクと深度範囲で読む。NYUv2 のみ Eigen crop を併用する。指標は Depth Pro [5] のスケール不変な境界 BF_1 で、5% から 25% までの 11 点の閾値で掃引する。各土台モデル自身の未鋭化の予測に対する BF_1 の相対変化を相対変化として報告する。予測は採点前にそれぞれの空間 (一方は log 深度、他方は視差) で正解に整合させる。この整合はすべての変種に等しく作用する。

実装の詳細。選別器の学習には AdamW を用い、学習率 3×10^{-4}、weight decay 10^{-4}、コサインスケジュール、30 エポック、バッチサイズ 4 とした。フレームは 480×640 のまま用い、リサイズもデータ拡張も行わない。帯と充填半径は画素単位で定義されるため、尺度を変えると $r_b = 2$ の意味が変わるからである。輪郭は Segment Anything [11] の ViT-H チェックポイントを自動モードで用い、32×32 のプロンプト格子と既定の品質フィルタで生成した。第 V 節の「grid 16」「grid 48」はこの格子を変えたものである。1 枚の輪郭集合は、得られた各マスクの幅 1 画素の境界の和であり、マスクそのものの和ではない。計測は RTX 4090 1 枚で行った。

B. 主結果

表 II は、アーキテクチャもパラメータ規模も出力表現も共有しない 2 つの深度モデルでの結果である。seed だけが異なる 4 つの選別器を、すべて Marigold V2 の予測で学習した。同じ 4 つを Lotus へ再学習なしで適用し、視差から log 深度への変換だけを加えている。Lotus 側の標準偏差は、その 4 つを Lotus に適用したときのばらつきであって、Lotus で学習した 4 モデルのばらつきではない。

第一のモデルでは seed 4 本すべてが +10% を超え、95% 信頼区間の下限は +10.49% である。画素単位の精度は劣化しない。AbsRel は 0.03881 から 0.03860 へ、δ_1 は 0.97969 から 0.98000 へ動く。いずれも変化は小さく、境界のために精度を犠牲にしていないということのみを主張する。

フレーム単位で採点すると、平均が少数のフレームに支えられているのではないことが分かる。651 枚のうち 484 枚（74.3%）で改善し、相対利得の中央値は +13.15%、第 1・第 3 四分位は −0.19% と +31.57% である。すなわち 4 枚に 1 枚はわずかに悪化している。ここで除いた 3 枚は、ベースライン BF_1 が 11 閾値すべてで 0 であり、相対利得が定義できない。プール値には 0 として含まれている。図 1 はこの分布の中ほどにあるフレームである。

TABLE III
Soft Edge Error。表 II の 4 SEED のうち +12.49% を出した 1 つ（4 本中 2 番目）を、両モデルにそのまま適用した値。小さいほど良く、% は各モデル自身のベースラインに対する相対変化。「GT 輪郭」は正解の不連続そのもので鋭化するもので、分割輪郭から選んで到達できる上限ではない。表 I のオラクル選別はこれとは別の、はるかに小さい上限である。

	BF_1	SEE_3	SEE_5	SEE_7
Marigold V2				
ベースライン	0.0884	0.1148	0.0882	0.0758
＋選別器	+12.49%	−3.34%	−2.89%	−2.39%
移設対照	−0.50%	+0.32%	+0.46%	+0.52%
GT 輪郭	+209.8%	−11.44%	−5.09%	−2.91%
Lotus				
ベースライン	0.0693	0.1403	0.1147	0.1014
＋選別器	+28.18%	−5.18%	−5.54%	−5.48%
移設対照	−0.57%	+0.20%	+0.23%	+0.24%
GT 輪郭	+279.0%	−12.96%	−9.81%	−8.73%

C. もう一つの境界指標

一つの指標でしか見えない改善は、その指標の定義による改善かもしれない。そこで Soft Edge Error [6] でも測った。Marigold V2 が採用している境界指標で、その実装から移植した。SEE_k は、正解の境界画素において、$k \times k$ 近傍のどれかの正解深度との絶対誤差の最小値を平均する。境界のズレは許し、にじみは罰する。BF_1 と違って深度単位の絶対誤差なのでスケール不変ではなく、採点前に整合させる必要がある。小さいほど良い。

2 つの指標は、両モデルのすべての変種で一致する。選別器は両方で改善、移設対照は両方で悪化、GT 輪郭での鋭化は両方で最良。したがって**この改善は BF_1 の定義の産物ではない**。

ただし変化の大きさは比較できない。SEE は境界画素の絶対誤差の平均で、その場所でのモデル自身の深度値の精度が下限になる。だから GT 輪郭での鋭化は BF_1 を 209.8% 上げる一方、SEE_5 は 5.09% しか下げない。また k が大きいほど改善が小さくなる（GT 輪郭で −11.44% から −2.91%）。大きい k ほどズレを許すのだから、これは SEE の定義から予想される挙動である。

D. 対照

利得は学習ではなく鋭化そのものから来ているのかもしれず、あるいは単に疎であることから来ているのかもしれない。表 IV は、学習を伴わない 5 つの代替手段を、各土台モデル自身の予測で測定したものである。

輪郭保存フィルタの行は古典的な代替手段である。画像を誘導画像とする guided filter ないし joint bilateral filter は、深度の境界を画像のエッジへ寄せる標準的な方法である。いずれも悪化し、しかも半径について単調に悪化する（最も緩い設定で −4.75%、最も強い設定で −50.14%）。フィルタは平滑化しかできず、平滑化された境界は BF_1 が減点する対象そのものである。本研究の操作が段差を復元できるのは、帯を捨てて両側をそれぞれ自分の側から埋め直すためである。

TABLE IV
学習を伴わない対照。土台モデルごとに別々に測定した BF_1 の変化。移設の行は独立な 3 回の移設の平均、ランダム 2 行は 3 回の抽出の平均で、いずれも選別器と同じ 1 枚ごとの予算を使う。

選別の方法	Marigold V2	Lotus
なし（全輪郭）	-1.90%	$+10.31\%$
輪郭保存フィルタ	-4.75%	—
移設（同じ疎さ・違う場所）	-0.50%	-0.57%
画素ランダム	$-24.96 \pm 0.53\%$	$-22.11 \pm 1.17\%$
ブロックランダム	$-1.04 \pm 0.15\%$	$-0.03 \pm 0.36\%$
手作り特徴の閾値（最良）	$+1.25\%$	$+10.46\%$
学習した選別器	$+$**11.92**%	$+$**27.83**%
学習の寄与	**10.7** pt	**17.4** pt

手作り特徴の対照は、予測深度の log 勾配の局所的な記述子に閾値を掛けるものである。その特徴量は、ホールドアウトでの順位付けの良さではなく test 集合の最終指標で選んだ。候補 4 つを測ると AUC の順位と BF_1 の順位は**逆転**し、AUC が最も低い特徴量（0.801）が BF_1 最良（$+1.25\%$）を、AUC が最も高い特徴量（0.876）が BF_1 最下位（-2.59%）を与える。これは本手法が持たない優位を対照に与えるので、比較は保守的になる。代理指標で選んだ対照は弱すぎることになり、弱い対照は比較される手法を良く見せるだけである。

ランダム 2 行は、選別器の出力から 1 枚ごとに取った同じ予算をちょうど使う。画素ランダムが両モデルで近い値（-24.96% と -22.11%）を示すのは、この対照が測っているのが鋭化操作の性質であって深度モデルの性質ではないからである。輪郭を連続させたままのブロックランダムは、どちらでもほとんど損をせず、Lotus では誤差の範囲で 0 である。画素ランダムをあれほど破壊的にしているのは選択を散らすことであり、選び方が悪いこと自体の代償はほとんど無い。

E. 分割モデルの寄与

分割モデルを完全に外し、選別器が RGB と深度から自力で境界を見つけ、有効画素すべてを候補とする設定では $+7.30\%$ となる。このアブレーションは両方とも単一 seed の値なので、比較すべきはその seed の $+12.49\%$ である。分割モデルの寄与は 5.19 ポイント、その実行の 42% にあたる。この寄与は適合率ではなく再現率の側から生じている。分割輪郭上で数えると真の段差は 1 枚あたり 1,345 画素で、予算 1,330 画素はその 98.9% を覆える。有効画素全体で数えると 2,941 画素あり、同じ予算では再現率の上限が 45.2% になる。分割モデルは正解の集合を絞ることによって寄与している。

V. 計算コスト

表 V は RTX 4090 1 枚での 1 フレームあたりの実時間である。ウォームアップ後に実フレームで測定した。Marigold V2 のトランスフォーマは、公開設定の既定である 4 bit NF4 で読み込まれる。したがって 213 億パラメータが占めるのはおよそ 10.6 GB で、24 GB のカードに載る。bf16 では載らない。

選別器は 12.0 ms、鋭化は 18.3 ms であり、本研究が追加するのは 30.3 ms、深度推定モデル自身の 495 ms の 6% である。それ以外をすべて支配するのは分割モデルで、点グリッドに応じて 534 ms から 2,603 ms を要する。

TABLE V
1 枚あたりの処理時間と、得られる改善量。grid 16 と 48 は表 II の 4 seed の平均と標準偏差、他の 2 行はそこで $+12.49\%$ を出した単一 seed の値である。効いてくる調整項は分割モデルの点グリッドだけである。

構成	ms/枚	BF_1 の変化	1 pt あたり
深度推定モデルのみ	495	—	—
＋選別器（分割なし）	525	$+7.30\%$	**72**
＋選別器・grid 16	**1,059**	$+$**11.02** $\pm$ **0.64**%	**96**
＋選別器・grid 32	1,996	$+11.17\%$	179
＋選別器・grid 48	3,128	$+11.92 \pm 0.90\%$	262

粗いグリッドでも同等の改善が得られる。grid 16 は grid 48 の利得の 92% を、分割コストの 20% で達成する。パイプライン全体の処理時間は 3.0 分の 1 となり、BF_1 改善 1 ポイントあたりの処理時間は約 2.7 分の 1 になる。差の 0.90 ポイントは seed 間の標準偏差 0.90 より小さく、1 組の実行では順序を決められない。ただし seed で対応をとると grid 48 が 4 本すべてで上回り、差は 0.90 ± 0.29 ポイント（$p = 0.009$）である。差は一貫しており、かつ小さい。適合率はグリッドをまたいで逆順に並ぶ（grid 16・32・48 で 51.6%・50.6%・50.2%、seed 1 本）。これは粗いグリッドが何をしているかを示している。大きな物体の輪郭を辿り、壁紙の柄や床の目地を取りこぼすため、候補に含まれる真の境界の割合がもともと高い。grid 48 は grid 16 より 1 枚あたり 3,200 画素多く輪郭を見つけるが、それで買える BF_1 は 0.90 ポイントである。増えた輪郭の大半が偽陽性だということである。これは前節のアブレーションと同じ機構 (分割モデルは正解の集合を絞ることで寄与する) が別の軸で現れたものである。

VI. 限界

5 つの標準ベンチマークのうち 2 つで評価した。BF_1 は隣接画素を比較するため、その両方が有効であるだけの密度を正解深度に要求する。土台モデルが評価される 5 つのベンチマークのうち 3 つはこれを満たさない。KITTI [15] は隣接ペアの 13.2%、ETH3D [16] は 4.1% しか有効でなく、DIODE [17] は密であるものの、評価プロトコルが本手法の対象である深度勾配を除外し、屋内の不連続の 99.4% が失われる。5 つのうち BF_1 が定義できるのは NYUv2 と ScanNet であり、本研究はその両方で評価した。加えて Hypersim でも評価するが、これは 5 つのうちの一つではなく、Marigold V2 自身の学習ドメインであり、第三の転移テストとして用いる。

本手法は深度モデルをまたいでは転移するが、データセットをまたいでは転移しない。表 VI は、NYUv2 で学習した選別器を ScanNet と Hypersim に適用した結果である（深度モデルは全行で Marigold V2）。

いずれの未見データセットでも、選別器は全輪郭を使う場合に及ばない。以下に示すように、これはデータセット自体の性質ではなく、学習ドメインと評価ドメインの不一致に起因すると考えられる。Hypersim 10,000 枚で学習した選別器は、Hypersim 自身では $+5.05\%$ に達する（選別なしは $+2.28\%$、適合率 88.1%、正例率 22.8%）。同じチェッ

TABLE VI
汎化。選別器は NYUv2 で学習しており、深度モデルは全行で Marigold V2 である。適合率はいずれも同じ残存率 6% で測った。

評価データ	選別なし	＋選別器	適合率
NYUv2（在ドメイン）	−1.90%	**+11.92%**	50.2%
ScanNet	+3.26%	+2.81%	17.4%
Hypersim	+2.28%	−4.64%	55.8%

クポイントは NYUv2 で −2.23%、ScanNet で +0.39% である。Hypersim も飽和していない (自身の GT 輪郭で鋭化すると +39.49% になる) ので、本手法は NYUv2 と同様に Hypersim の在ドメインでも働き、学習と利用でドメインが変わったときにだけ働かなくなる。

残る 3 通りの対処は失敗した。RGB チャネルを落とすと、転移はむしろ悪化した。ScanNet で残存率を 2% から 20% まで掃引しても、選別なしに届く設定は無かった。NYUv2 795 枚と Hypersim 795 枚を等量混合して学習すると、在ドメインの結果を損ない、転移も改善しなかった。データ量もこの差を説明しない。NYUv2 を 393 枚に削ると利得は 2.2 ポイント（+11.92% から +9.72%、seed 2 本）下がるが、在ドメインと ScanNet の差は 9.1 ポイントある。

これを報告するのは、この分野の先行研究が行う主張に関わるからである。モデル非依存な後処理が、それゆえにデータセット非依存であるとは限らない。2 種類の汎化は分離しうると考えられる。

適合率は 3 行を並べない。NYUv2 で学習した選別器は、在ドメインよりも Hypersim で適合率が高い（50.2% に対し 55.8%）のに、結果はそこで最悪である。そもそも適合率はデータセットをまたいで比較できない。輪郭画素のうち真の段差に乗っている割合が異なり、NYUv2 の 6.07% に対し Hypersim は 22.8% である。3 行を分けているのは、評価データが選別器の学習ドメインと一致するかどうかであり、それを測れる量に還元することは著者らにはできていない。

上限までの余地。第 III-D 節のオラクル選別は +43.39% に達するのに対し、本手法は +11.92% であり、選別が与えうるものの 72.5% が未回収である。差は適合率にある（50.2% 対オラクルの 100%）。

指標の範囲。改善しているのは境界指標である。AbsRel と δ_1 の変化は改善と主張するには小さすぎ、劣化していないことのみを主張する。

ラベルと指標が定義を共有している。教師は「正解の深度段差から 1 px 以内」であり、BF_1 も正解の深度段差との一致を測る。正解データは推論に一切現れず、評価シーンは学習と重複しない。ただし両者が同じ定義を共有している点は、結果の解釈に影響しうる。

VII. おわりに

単眼深度に対する後処理の境界鋭化が、境界のすでに整ったモデルで失敗するのは、輪郭の位置が悪いからではなく、その大半が深度段差を示していないからである。修正操作を固定して対象だけを学習することで、利得の帰属が明確になり、1 枚あたり 30 ms・193 万パラメータで、再学習なしに深度モデルをまたいで転移する。依存する領域分割は、最も粗いグリッドでもさらに 534 ms を要する。データセットをまたいでは転移せず、著者らはそれを修復できなかった。

References

[1] B. Ke, A. Obukhov, S. Huang, N. Metzger, R. C. Daudt, and K. Schindler, “Repurposing diffusion-based image generators for monocular depth estimation,” in *CVPR*, 2024.

[2] J. He, H. Li, W. Yin et al., “Lotus: Diffusion-based visual foundation model for high-quality dense prediction,” in *ICLR*, 2025.

[3] I. Pavlovic, T. Wandel, A. Obukhov, L. Bartolomei, A. Davydov, F. Tosi, M. Poggi, S. Süsstrunk, and D. Dai, “Marigold V2: Revisiting diffusion transformers for monocular depth estimation,” arXiv:2609.08084, 2026.

[4] G. M. Garcia, K. Knaebel, C. Schmidt, D. de Geus, A. Hermans, and B. Leibe, “Fine-tuning image-conditional diffusion models is easier than you think,” in *WACV*, 2025.

[5] A. Bochkovskii et al., “Depth Pro: Sharp monocular metric depth in less than a second,” in *ICLR*, 2025.

[6] F. Tosi, Y. Liao, C. Schmitt, and A. Geiger, “SMD-Nets: Stereo mixture density networks,” in *CVPR*, 2021.

[7] M. Ramamonjisoa, Y. Du, and V. Lepetit, “Predicting sharp and accurate occlusion boundaries in monocular depth estimation using displacement fields,” in *CVPR*, 2020.

[8] M. Ramamonjisoa and V. Lepetit, “SharpNet: Fast and accurate recovery of occluding contours in monocular depth estimation,” in *ICCV Workshops*, 2019.

[9] K.-S. Peng, G. Ditzler, and J. Rozenblit, “Edge-guided occlusion fading reduction for a light-weighted self-supervised monocular depth estimation,” arXiv:1911.11705, 2019.

[10] A. Muthukkumar, “Bayesian monocular depth refinement via neural radiance fields,” in *Proc. IEEE 8th Int. Conf. Algorithms, Computing and Artificial Intelligence (ACAI)*, 2025, pp. 488–492.

[11] A. Kirillov et al., “Segment Anything,” in *ICCV*, 2023.

[12] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, “Indoor segmentation and support inference from RGBD images,” in *ECCV*, 2012.

[13] A. Dai, A. X. Chang, M. Savva, M. Halber, T. Funkhouser, and M. Nießner, “ScanNet: Richly-annotated 3D reconstructions of indoor scenes,” in *CVPR*, 2017.

[14] M. Roberts et al., “Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding,” in *ICCV*, 2021.

[15] A. Geiger, P. Lenz, and R. Urtasun, “Are we ready for autonomous driving? The KITTI vision benchmark suite,” in *CVPR*, 2012.

[16] T. Schöps, J. L. Schönberger, S. Galliani, T. Sattler, K. Schindler, M. Pollefeys, and A. Geiger, “A multi-view stereo benchmark with high-resolution images and multi-camera videos,” in *CVPR*, 2017.

[17] I. Vasiljevic et al., “DIODE: A dense indoor and outdoor depth dataset,” arXiv:1908.00463, 2019.