# 拡散単眼深度推定における選択的な境界鋭化

TODO 著者名
*TODO* 専攻・学科
*TODO* 大学
TODO 市, 国
TODO メールアドレス

***Abstract*—拡散モデルに基づく単眼深度推定は滑らかな面の精度は高いが、深度の不連続（物体境界）がぼやけるという欠点がある。セグメンテーションモデルが見つけた輪郭で予測深度を鋭化するのが自然な対処だが、すべての輪郭に鋭化を掛けると境界 $BF_1$ は 1.9% 悪化する。本研究では、この悪化が深度段差を伴わない輪郭への鋭化に起因することに着目し、鋭化操作は固定したまま、適用すべき輪郭のみを学習によって選別する手法を提案する。NYUv2 において提案手法は境界 $BF_1$ を 11.9% 改善し（4 seed 平均）、同じ選別器を再学習なしにアーキテクチャと出力表現の異なる深度モデルへ適用しても 27.8% の改善を得た。一方で、選別器はデータセットをまたいでは転移しないことも報告する。**

***Index Terms*—単眼深度推定, 深度境界, 後処理, 拡散モデル**

## I. はじめに

近年、大規模な画像生成モデルが持つ事前知識を単眼深度推定に転用する研究が進んでいる。Marigold [1] は画像生成用の拡散モデル Stable Diffusion を合成 RGB-D データで微調整し、少量の学習データから高い汎化性能を持つ深度推定器を構築した。Lotus [2] はこれを発展させ、多段の拡散過程を 1 ステップの予測に置き換えることで、精度を保ったまま推論を大幅に高速化した。さらに Marigold V2 [3] は、画像編集用の拡散トランスフォーマを土台とすることで精度を一段と高めている。

一方で、これらの手法には物体境界における深度の不連続がぼやけるという課題がある。生成モデルが持つ滑らかさの事前知識や、解像度を落とした潜在空間上で予測を行う構造に起因すると考えられ、遮蔽境界の段差が数画素にわたってにじむ。AbsRel のような画素平均の指標では、境界画素が画像のごく一部にすぎないためこの劣化は表に現れにくく、境界専用の指標によって明らかになる [5]。

深度モデルに手を加えずに済み、任意のモデルの出力に適用できることから、境界を後処理で改善する方針は魅力的である。先行研究は、遮蔽境界の周囲で画素を再配置する変位場の学習 [7] や、境界を保存する視差合成 [9] など、深度をどう修正するかを学習してきた。

より単純な対処として、セグメンテーションの結果を手がかりにする方法が考えられる。Segment Anything [11] のようなセグメンテーションモデルは、画像を物体や領域ごとに切り分け、その輪郭を高い精度で抽出できる。物体の輪郭は多くの場合、深度が不連続に変わる位置と一致する。そこで、輪郭を境に予測深度を両側から埋め直し、ぼやけた段差を急峻にする（以下、鋭化と呼ぶ）。しかし Marigold V2 に対してすべての輪郭へ鋭化を適用すると、境界 $BF_1$ はかえって 1.9% 低下する。セグメンテーション輪郭の大半（79.8%）は壁紙の柄や床の目地のように、輪郭ではあっても深度段差を伴わないためである。そこへ鋭化を適用すると、存在しない不連続を導入してしまう。

この結果は、鋭化の成否が輪郭の位置よりも、どの輪郭に適用するかで決まることを示唆している。実際、正解データを用いて深度段差上の輪郭のみを選ぶと、輪郭の位置を一切変えずに効果は改善に転じる。そこで本研究では、鋭化操作は固定したまま、適用すべき輪郭のみを学習によって選別する手法を提案する。選別器は RGB 画像・予測深度・輪郭を入力とする小規模な U-Net であり、深度モデルとセグメンテーションモデルは凍結する。学習するのは選別器だけであるため、得られた改善を選別の学習に帰属させることができる。NYUv2 において提案手法は境界 $BF_1$ を 11.9% 改善し、同じ選別器を再学習なしに Lotus へ適用しても 27.8% の改善を得た。

本研究の貢献は次の 3 点である。

1) 鋭化操作を固定し、その適用対象の輪郭のみを学習によって選別する後処理手法を提案した（第 III 節）。
2) 提案手法が、学習を伴わない対照や古典的な輪郭保存フィルタを上回り、境界精度を改善することを示した（第 IV 節）。
3) 提案手法が再学習なしに深度モデル間で転移する一方、データセット間では転移しないことを示した（第 IV 節、第 VI 節）。

## II. 関連研究

**拡散ベースの単眼深度推定。**上記のモデルに加え、1 ステップでの微調整がこれらの手法を単純化し、桁違いに高速化することが示されている [4]。本研究は、この系統の中で可能な限り離れた 2 つのモデルで評価する。一つは Marigold V2（4 bit QLoRA で微調整された 213 億パラメータの拡散トランスフォーマ、アフィン不変な log 深度を出力）、もう一つは Lotus（8.68 億パラメータの UNet、視差を出力）である。

**後処理としての境界鋭化。**Ramamonjisoa らの研究 [7] が最も近い。任意の深度推定器の出力に適用でき、NYUv2 の学習 795 枚・評価 654 枚という使い方まで本研究と同一である。SharpNet [8] は遮蔽輪郭の回復を深度ネットワーク自身の学習に組み込み、NeRF による深度精緻化 [10] は単眼推定と再構成された場を融合する。著者らの知る限り、修正操作を固定して対象だけを学習する研究はなく、またプロンプト可能なセグメンテーションモデルを境界候補の供給源として用いる研究もない。Segment Anything [11] はむしろ逆に、深度を事前情報としてマスクを精緻化する方向で用いられてきた。

**直接比較は行っていない。**[7] は学習済み重みが公開されておらず、公開実装も現行の実行環境では動作しないため、

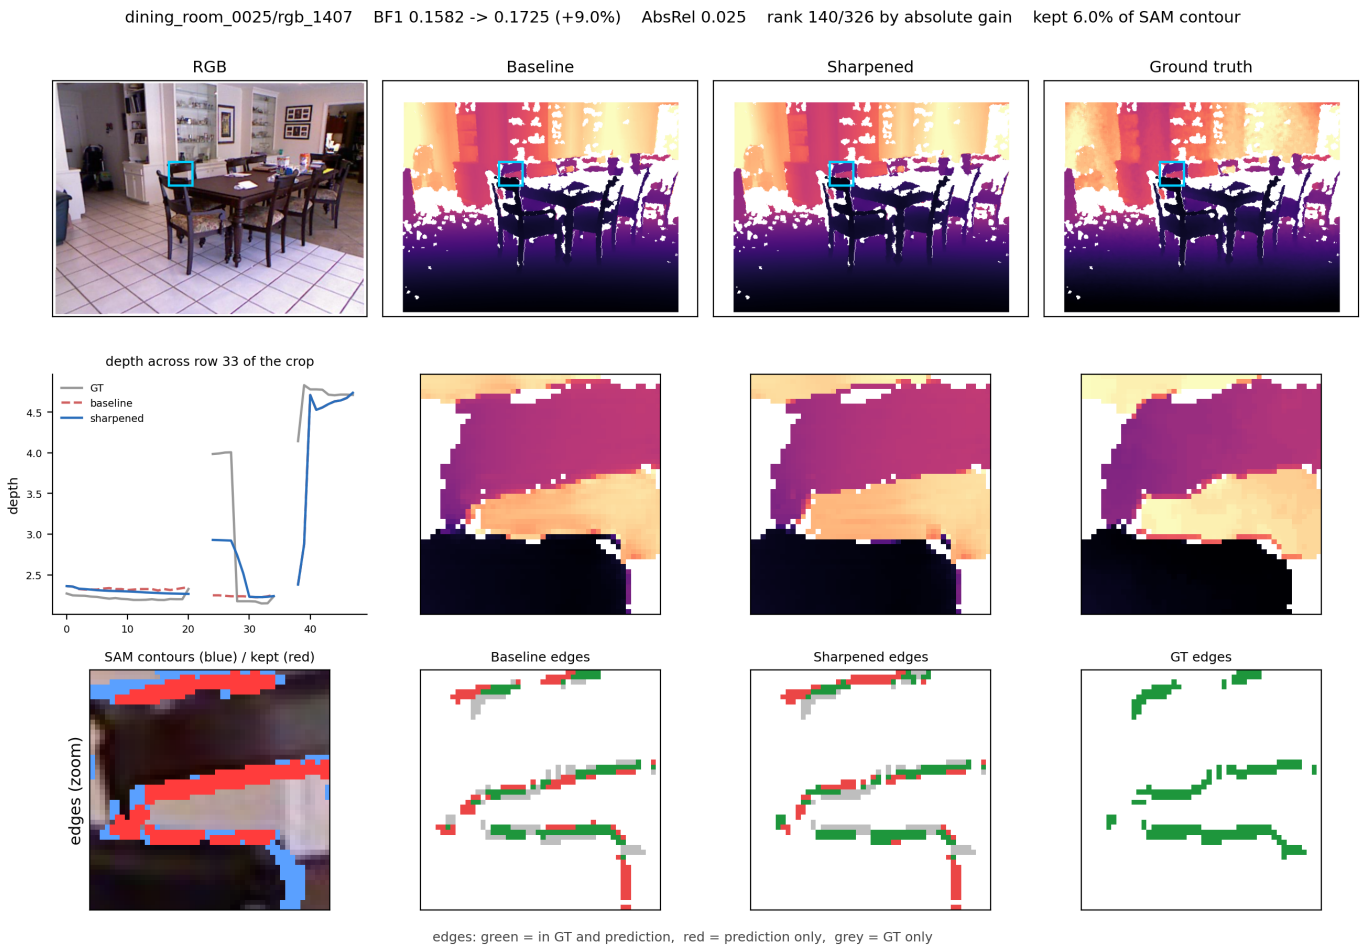



Fig. 1. 提案手法の動作例（ダイニングルームのフレーム）。上段は画像全体で、選別された輪郭の周囲の帯の外側は変化しない。中段は椅子の背もたれの境界を 48 px で切り出したもので、左端にその断面の深度プロファイルを示す。ベースラインは正解が持つ 2 つの段差をいずれも捉えていないが、鋭化後は両方が再現されている。修正が書き換える帯は 2 画素幅であるため、中段の 3 枚は切り出し範囲から求めた共通のカラースケールで表示している。下段は各深度マップが含む不連続エッジで、これが $BF_1$ の比較対象である。緑は正解と予測の両方、赤は予測のみ、灰は正解のみ。このフレームは、AbsRel が評価集合の中央値 0.0303 以下である 326 枚を絶対利得で並べたときの 140 位であり、相対利得 $+9.01\%$ は評価集合の中央値 $+13.15\%$ を下回る。正確な側の半分に限ったのは、破綻した予測を立て直す例ではなく良い予測を鋭化する例を示すためである。

本稿では直接比較を行わない。同一条件での再実装による比較は今後の課題とする。

**境界指標。** Depth Pro [5] のスケール不変な境界 $BF_1$ を採用する。隣接画素間の深度の**比**が閾値を超えたときに深度段差があると判定し、その閾値を掃引する指標である。本研究は新しい指標を提案しない。Lotus も Marigold V2 も NYUv2 の $BF_1$ を報告していないため、ベースラインは著者らが測定した。

## III. 手法

図 2 にパイプラインを示す。深度推定モデルとセグメンテーションモデルは凍結する。修正は第 III-A 節の固定操作で、何も学習しない。学習する構成要素は選別器だけである。第 III-B 節がこの設計の動機を示す。

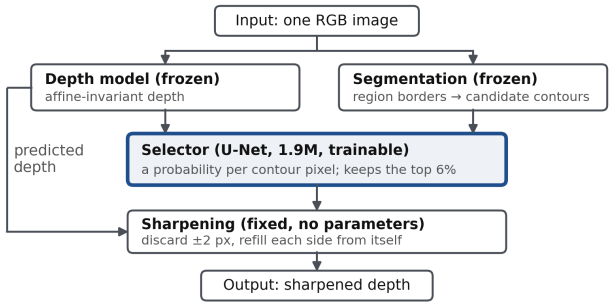



Fig. 2. 学習するのは選別器だけ。深度推定モデルもセグメンテーションモデルも凍結し、修正操作はパラメータを持たない固定操作である。したがって利得は選別のみに帰属する。

### A. 修正操作

この操作を**障壁鋭化**と呼ぶ。選別された輪郭を、深度を内挿してはならない障壁として扱うためである。$z$ を予測深度、$V$ をその有効画素、$C \subseteq V$ を輪郭画素の集合とする。操作はまず帯

$$B = \{\, p \in V \mid \mathrm{dist}(p, C) \le r_b \,\}, \qquad r_b = 2 \tag{1}$$

TABLE I
MARIGOLD V2 で後処理による鋭化が失敗する理由と、何がそれを直すか。NYUv2 654 枚。オラクル選別は正解データを用いてセグメンテーション輪郭の部分集合を選ぶもので、輪郭は 1 画素も動かさない。

| 鋭化した輪郭 | 残存率 | $BF_1$ の変化 |
|---|---|---|
| セグメンテーションモデルの全輪郭 | 100% | $-1.90\%$ |
| オラクル選別（段差から 1 px 以内） | 6.07% | $+\mathbf{43.39}\%$ |

を捨て、$V \setminus B$ の連結成分にラベルを付ける。これにより輪郭の両側は異なるラベルを持つ。次にラベルを 1 画素ずつ内側へ伝播させて $B$ を覆い、各 $p \in B$ にラベル $\ell(p)$ を与える。捨てた画素は自分の側からのみ埋め直す。

$$\hat{z}(p) = \frac{1}{|N(p)|} \sum_{q \in N(p)} z(q) \tag{2}$$

ここで $N(p) = \{\, q \notin B \mid \|q - p\| \le r_f,\ \ell(q) = \ell(p) \,\}$、$r_f = 3$ である。$B$ の外側の画素は変化しない。帯を捨てるのは、拡散モデルが境界をまたいで値を内挿するためである。片側だけから埋め直すことで、この混ざりを除去する。成分ラベルは輪郭そのものから作るのであって、セグメンテーションマスクからではない。この操作は設定値を 2 つ持つだけで、学習するものは何もない。$r_f > r_b$ である必要があり、さもなければ $N(p)$ が空になり、操作は深度マップを変更しない。

両側が分かれるのは、輪郭が閉じているか画像端に達している場合だけである。画像の内側で途切れる輪郭では、その先端を回り込んで有効領域がつながるため、そこでは帯の両側が同一の連結成分に属し、片側からの補間が成立しない。選別はこれが生じる箇所を増やす。輪郭画素の 6% を残すと、輪郭は全体の輪ではなく断片になるからである。いずれも修復を弱める性質であり、本稿のすべての数値にそのまま含まれている。

### *B.* 全輪郭に掛けると失敗する

NYUv2 で Segment Anything が描く輪郭すべてにこの操作を掛けると、Marigold V2 の境界 $BF_1$ は 1.90% 低下する（表 I）。これは境界がすでにある程度正しいモデルに固有である。境界がもともと鈍い Lotus（ベースライン $BF_1$ 0.0693 対 0.0884）では、同じ無選別の鋭化が逆に 10.31% **改善**する（表 IV）。

### *C.* 位置精度は問題ではない

真の深度不連続それぞれから最寄りの輪郭までの距離を測ると、中央値 1.00 px、66.9% が 1 px 以内、76.9% が 2 px 以内である。輪郭は境界のある場所にあるが、輪郭画素の 79.8% は、半径 8 画素の窓の中に深度段差を一つも持たない。これらは壁紙の柄、床の目地、ポスターの縁である。そこへ鋭化を適用すると、平坦な領域に誤った不連続を導入することになる。

### *D.* 正解で選別すると符号が反転する

79.8% は半径 8 画素の窓という緩い基準、以下の選別は 1 画素という厳しい基準である。1 枚あたり 22,167 画素あるセグメンテーション輪郭 (有効画素の 10.6%) のうち、真の不連続から 1 px 以内にあるのは 1,345 画素、すなわち 6.07% である。それをちょうど残し、残した輪郭はすべて元の位置に置いたまま鋭化すると、効果は $-1.90\%$ から $+43.39\%$ へ動く（表 I）。この実験では輪郭の位置を変更しておらず、鋭化を適用する輪郭の集合のみが異なる。したがって性能低下の主因は輪郭の位置精度ではなく、適用対象の選別にあると考えられる。この結果に基づき、第 III-E 節では選別を学習によって行う。

### *E.* 選別器

**入力と出力。**選別器は 4 段の U-Net で、パラメータ数は 193 万である。RGB 画像（3 チャネル）、予測深度（1）、輪郭マスク（1）を入力し、画素ごとに 1 つのロジットを出す。予測深度は画像ごとに標準化する。この手順を省くと、学習時と推論時で水準や尺度が食い違ってもエラーは生じず、最終的な指標だけが目立たない形で悪化する。log 深度ではなく視差 $v$ を出すモデルに対しては、先に $-\log \max(v, 10^{-3})$ を適用する。視差は深度が小さいほど大きくなるためそのまま与えると符号の反転した信号を渡すことになり、またアフィン不変な視差は 0 以下にもなりうるので、下限でクリップする。これは深度について単調だが、log 深度のアフィン変換ではない。視差の未知のシフトは対数を通って非線形性として残り、画像ごとの標準化では落ちない。それでも選別器はそのまま適用しており、表 II の Lotus 列がこの近似の価値である。

**残存率。**確率の閾値ではなく、画像ごとに上位 6% の輪郭画素を残す。予算を 6% としたのは、学習フレームにおける正例率がこの値だからである（輪郭画素の 6.066% が真の段差から 1 px 以内にある）。閾値を固定すると、場面に含まれる輪郭の量によって残す量が変わり、鋭化が使う予算がフレームごとに動いてしまう。

**損失と学習。**選別器は、輪郭画素の上だけで平均した二値交差エントロピーで学習する。有効画素のうち輪郭でない 89% は、選別器に問うていない問題である。輪郭画素は、正解深度の不連続から 1 px 以内にあれば正例とする。ここで不連続とは深度比 10% 超の段差である。この閾値は test 集合ではなく検証集合で選んだ。学習 795 枚から外した 40 シーン・141 枚で $BF_1$ を測ると、10% が $+12.74\%$ で、15・20・25% の $+8.66$・$+6.29$・$+5.28\%$ を上回る。閾値を上げると正例が輪郭画素の 6.07% から 2.13% まで減り、固定の予算がほとんど負例に費やされるためである。本手法のハイパーパラメータは、閾値も残存率もすべて検証集合で決定した（第 IV-D 節の対照は例外で、その旨を同節に記す）。正解データはラベル生成にのみ用い、推論時には使用しない。NYUv2 の学習用 795 枚をシーン単位で分け、654 枚を学習、141 枚を検証に充てる。配備するチェックポイントは検証適合率が最良のエポックのもので、見ているのはこの 654 枚だけであり、評価用の 654 枚とは別の集合である。学習は RTX 4090 1 枚で 16 分・VRAM 3.5 GB を要し、評価集合には一度も触れない。

## IV. 実験

### *A.* 設定

NYUv2 [12] の評価用 654 枚で評価する。学習フレームとはシーンが重複しない。第 VI 節の転移先は、[3] が用いる ScanNet [13] の検証用 800 枚と、Hypersim [14] のシーン単位ホールドアウト 300 枚である。いずれも深度を 16 bit

TABLE II
主結果。SEED 4 本、± は標準偏差。同じ 4 つの選別器を両モデルに適用しており、学習は第一のモデルでのみ行った。絶対値では $BF_1$ が 0.0884 から 0.0989 へ、0.0693 から 0.0886 へ変化する。

| 土台の深度モデル | $BF_1$ | 選別なし | ＋選別器 |
|---|---|---|---|
| Marigold V2・213 億・log | 0.0884 | −1.90% | +**11.92** ± **0.90**% |
| Lotus・8.68 億・視差 | 0.0693 | +10.31% | +**27.83** ± **1.27**% |

ミリメートルで保持し、各データセット固有の有効マスクと深度範囲で読む。NYUv2 のみ Eigen crop を併用する。指標は Depth Pro [5] のスケール不変な境界 $BF_1$ で、5% から 25% までの 11 点の閾値で掃引する。各土台モデル自身の未鋭化の予測に対する $BF_1$ の相対変化を相対変化として報告する。予測は採点前にそれぞれの空間 (一方は log 深度、他方は視差) で正解に整合させる。この整合はすべての変種に等しく作用する。

**実装の詳細。**選別器の学習には AdamW を用い、学習率 $3 \times 10^{-4}$、weight decay $10^{-4}$、コサインスケジュール、30 エポック、バッチサイズ 4 とした。フレームは $480 \times 640$ のまま用い、リサイズもデータ拡張も行わない。帯と充填半径は画素単位で定義されるため、尺度を変えると $r_b = 2$ の意味が変わるからである。輪郭は Segment Anything [11] の ViT-H チェックポイントを自動モードで用い、$48 \times 48$ のプロンプト格子と既定の品質フィルタで生成した。第 V 節の「grid 16」「grid 32」はこの格子を変えたものである。1 枚の輪郭集合は、得られた各マスクの幅 1 画素の境界の和であり、マスクそのものの和ではない。計測は RTX 4090 1 枚で行った。

### *B.* 主結果

表 II は、アーキテクチャもパラメータ規模も出力表現も共有しない 2 つの深度モデルでの結果である。seed だけが異なる 4 つの選別器を、すべて Marigold V2 の予測で学習した。同じ 4 つを Lotus へ再学習なしで適用し、視差から log 深度への変換だけを加えている。Lotus 側の標準偏差は、その 4 つを Lotus に適用したときのばらつきであって、Lotus で学習した 4 モデルのばらつきではない。

第一のモデルでは seed 4 本すべてが +10% を超え、95% 信頼区間の下限は +10.49% である。画素単位の精度は劣化しない。AbsRel は 0.03881 から 0.03860 へ、$\delta_1$ は 0.97969 から 0.98000 へ動く。いずれも変化は小さく、境界のために精度を犠牲にしていないということのみを主張する。

フレーム単位で採点すると、平均が少数のフレームに支えられているのではないことが分かる。651 枚のうち 484 枚（74.3%）で改善し、相対利得の中央値は +13.15%、第 1・第 3 四分位は −0.19% と +31.57% である。すなわち 4 枚に 1 枚はわずかに悪化している。ここで除いた 3 枚は、ベースライン $BF_1$ が 11 閾値すべてで 0 であり、相対利得が定義できない。プール値には 0 として含まれている。図 1 はこの分布の中ほどにあるフレームである。

### *C.* もう一つの境界指標

一つの指標でしか見えない改善は、その指標の定義による改善かもしれない。そこで Soft Edge Error [6] でも測った。Marigold V2 が採用している境界指標で、その実装から移植した。$SEE_k$ は、正解の境界画素において、$k \times k$ 近傍のどれかの正解深度との絶対誤差の最小値を平均する。境界のズレは許し、にじみは罰する。$BF_1$ と違って深度単位の絶対誤差なのでスケール不変ではなく、採点前に整合させる必要がある。小さいほど良い。

TABLE III
SOFT EDGE ERROR。表 II の 4 SEED のうち +12.49% を出した 1 つ（4 本中 2 番目）を、両モデルにそのまま適用した値。小さいほど良く、% は各モデル自身のベースラインに対する相対変化。「GT 輪郭」は正解の不連続そのもので鋭化するもので、セグメンテーション輪郭から選んで到達できる上限ではない。表 I のオラクル選別はこれとは別の、はるかに小さい上限である。

| | $BF_1$ | $SEE_3$ | $SEE_5$ | $SEE_7$ |
|---|---|---|---|---|
| *Marigold V2* | | | | |
| ベースライン | 0.0884 | 0.1148 | 0.0882 | 0.0758 |
| ＋選別器 | +12.49% | −3.34% | −2.89% | −2.39% |
| 移設対照 | −0.50% | +0.32% | +0.46% | +0.52% |
| GT 輪郭 | +209.8% | −11.44% | −5.09% | −2.91% |
| *Lotus* | | | | |
| ベースライン | 0.0693 | 0.1403 | 0.1147 | 0.1014 |
| ＋選別器 | +28.18% | −5.18% | −5.54% | −5.48% |
| 移設対照 | −0.57% | +0.20% | +0.23% | +0.24% |
| GT 輪郭 | +279.0% | −12.96% | −9.81% | −8.73% |

TABLE IV
学習を伴わない対照。土台モデルごとに別々に測定した $BF_1$ の変化。移設の行は独立な 3 回の移設の平均、ランダム 2 行は 3 回の抽出の平均で、いずれも選別器と同じ 1 枚ごとの予算を使う。フィルタの行は GUIDED FILTER と JOINT BILATERAL FILTER を 4 通りの半径で試した最良値で、両モデルとも JOINT BILATERAL・半径 1 である。

| 手法 | Marigold V2 | Lotus |
|---|---|---|
| なし（全輪郭） | −1.90% | +10.31% |
| 移設（同じ疎さ・違う場所） | −0.50% | −0.57% |
| 画素ランダム | −24.96 ± 0.53% | −22.11 ± 1.17% |
| ブロックランダム | −1.04 ± 0.15% | −0.03 ± 0.36% |
| 手作り特徴の閾値（最良） | +1.25% | +10.46% |
| joint bilateral filter, $r$=1 | −4.75% | −7.15% |
| **学習した選別器** | +**11.92**% | +**27.83**% |
| **学習の寄与** | **10.7** pt | **17.4** pt |

**2 つの指標は、両モデルのすべての変種で一致する。**選別器は両方で改善、移設対照は両方で悪化、GT 輪郭での鋭化は両方で最良。したがって**この改善は $BF_1$ の定義の産物ではない**。

ただし変化の大きさは比較できない。SEE は境界画素の絶対誤差の平均で、その場所でのモデル自身の深度値の精度が下限になる。だから GT 輪郭での鋭化は $BF_1$ を 209.8% 上げる一方、$SEE_5$ は 5.09% しか下げない。また $k$ が大きいほど改善が小さくなる（GT 輪郭で −11.44% から −2.91%）。大きい $k$ ほどズレを許すのだから、これは SEE の定義から予想される挙動である。

### *D.* 対照

利得は学習ではなく鋭化そのものから来ているのかもしれず、あるいは単に疎であることから来ているのかもしれない。表 IV は、学習を伴わない 6 つの代替手段を、各土台モデル自身の予測で測定したものである。

フィルタの行は古典的な代替手段である。画像を誘導画像とする guided filter ないし joint bilateral filter は、深度の境界を画像のエッジへ寄せる標準的な方法である。いずれも両モデルで悪化し、しかも半径について単調に悪化する（最も緩い設定で $-4.75\%$・$-7.15\%$、最も強い設定で $-50.14\%$・$-45.30\%$）。フィルタは平滑化しかできず、平滑化された境界は $\mathrm{BF}_1$ が減点する対象そのものである。本研究の操作が段差を復元できるのは、帯を捨てて両側をそれぞれ自分の側から埋め直すためである。

手作り特徴の対照は、予測深度の log 勾配の局所的な記述子に閾値を掛けるものである。その特徴量は、ホールドアウトでの順位付けの良さではなく test 集合の最終指標で選んだ。候補 4 つを測ると AUC の順位と $\mathrm{BF}_1$ の順位は**逆転**し、AUC が最も低い特徴量（0.801）が $\mathrm{BF}_1$ 最良（$+1.25\%$）を、AUC が最も高い特徴量（0.876）が $\mathrm{BF}_1$ 最下位（$-2.59\%$）を与える。これは本手法が持たない優位を対照に与えるので、比較は保守的になる。代理指標で選んだ対照は弱すぎることになり、弱い対照は比較される手法を良く見せるだけである。

ランダム 2 行は、選別器の出力から 1 枚ごとに取った同じ予算をちょうど使う。画素ランダムが両モデルで近い値（$-24.96\%$ と $-22.11\%$）を示すのは、この対照が測っているのが鋭化操作の性質であって深度モデルの性質ではないからである。輪郭を連続させたままのブロックランダムは、どちらでもほとんど損をせず、Lotus では誤差の範囲で 0 である。画素ランダムをあれほど破壊的にしているのは選択を散らすことであり、選び方が悪いこと自体の代償はほとんど無い。

### *E.* セグメンテーションモデルの寄与

セグメンテーションモデルを完全に外し、選別器が RGB と深度から自力で境界を見つけ、有効画素すべてを候補とする設定では $+7.30\%$ となる。このアブレーションは両方とも単一 seed の値なので、比較すべきはその seed の $+12.49\%$ である。セグメンテーションモデルの寄与は 5.19 ポイント、その実行の 42% にあたる。この寄与は適合率ではなく再現率の側から生じている。セグメンテーション輪郭上で数えると真の段差は 1 枚あたり 1,345 画素で、予算 1,330 画素はその 98.9% を覆える。有効画素全体で数えると 2,941 画素あり、同じ予算では再現率の上限が 45.2% になる。セグメンテーションモデルは正解の集合を絞ることによって寄与している。

## V. 計算コスト

表 V は RTX 4090 1 枚での 1 フレームあたりの実時間である。ウォームアップ後に実フレームで測定した。Marigold V2 のトランスフォーマは、公開設定の既定である 4 bit NF4 で読み込まれる。したがって 213 億パラメータが占めるのはおよそ 10.6 GB で、24 GB のカードに載る。bf16 では載らない。

選別器は 12.0 ms、鋭化は 18.3 ms であり、本研究が追加するのは 30.3 ms、深度推定モデル自身の 495 ms の 6% である。それ以外をすべて支配するのはセグメンテーションモデルで、点グリッドに応じて 534 ms から 2,603 ms を要する。

TABLE V
1 枚あたりの処理時間と、得られる改善量。GRID 16 と 48 は表 II の 4 SEED の平均と標準偏差、他の 2 行はそこで $+12.49\%$ を出した単一 SEED の値である。大きな影響を持つ設定はセグメンテーションモデルの点グリッドのみである。

| 構成 | ms/枚 | $\mathrm{BF}_1$ の変化 | 1 pt あたり |
|---|---|---|---|
| 深度推定モデルのみ | 495 | — | — |
| ＋選別器・SAM なし | 525 | $+7.30\%$ | **72** |
| ＋選別器・grid 16 | **1,059** | $+\mathbf{11.02 \pm 0.64}\%$ | **96** |
| ＋選別器・grid 32 | 1,996 | $+11.17\%$ | 179 |
| ＋選別器・grid 48 | 3,128 | $+11.92 \pm 0.90\%$ | 262 |

**粗いグリッドでも同等の改善が得られる。**grid 16 は grid 48 の利得の 92% を、セグメンテーションのコストの 20% で達成する。パイプライン全体の処理時間は 3.0 分の 1 となり、$\mathrm{BF}_1$ 改善 1 ポイントあたりの処理時間は約 2.7 分の 1 になる。差の 0.90 ポイントは seed 間の標準偏差と等しく、1 組の実行では順序を決められない。ただし seed で対応をとると grid 48 が 4 本すべてで上回り、差は $0.90 \pm 0.29$ ポイント（対応のある $t$ 検定、$p = 0.009$）である。差は一貫しており、かつ小さい。適合率はグリッドをまたいで逆順に並ぶ（grid 16・32・48 で 51.6%・50.6%・50.2%、seed 1 本）。これは粗いグリッドが何をしているかを示している。大きな物体の輪郭を辿り、壁紙の柄や床の目地を取りこぼすため、候補に含まれる真の境界の割合がもともと高い。grid 48 は grid 16 より 1 枚あたり 3,200 画素多く輪郭を見つけるが、それで得られる $\mathrm{BF}_1$ は 0.90 ポイントである。増えた輪郭の大半が偽陽性だということである。これは前節のアブレーションと同じ機構 (セグメンテーションモデルは正解の集合を絞ることで寄与する) が別の軸で現れたものである。

## VI. 限界

**5 つの標準ベンチマークのうち 2 つで評価した。**$\mathrm{BF}_1$ は隣接画素を比較するため、その両方が有効であるだけの密度を正解深度に要求する。土台モデルが評価される 5 つのベンチマークのうち 3 つはこれを満たさない。KITTI [15] は隣接ペアの 13.2%、ETH3D [16] は 4.1% しか有効でなく、DIODE [17] は密であるものの、評価プロトコルが本手法の対象である深度勾配を除外し、屋内の不連続の 99.4% が失われる。5 つのうち $\mathrm{BF}_1$ が定義できるのは NYUv2 と ScanNet であり、本研究はその両方で評価した。加えて Hypersim でも評価するが、これは 5 つのうちの一つではなく、Marigold V2 自身の学習ドメインであり、第三の転移テストとして用いる。

**本手法は深度モデルをまたいでは転移するが、データセットをまたいでは転移しない。**表 VI は、NYUv2 で学習した選別器を ScanNet と Hypersim に適用した結果である（深度モデルは全行で Marigold V2）。

いずれの未見データセットでも、選別器は全輪郭を使う場合に及ばない。以下に示すように、これはデータセット自体の性質ではなく、学習ドメインと評価ドメインの不一致に起因すると考えられる。Hypersim 10,000 枚で学習した選別器は、Hypersim 自身では $+5.05\%$ に達する（選別なしは $+2.28\%$、適合率 88.1%、正例率 22.8%）。同じチェックポイントは NYUv2 で $-2.23\%$、ScanNet で $+0.39\%$ である。Hypersim も飽和していない (自身の GT 輪郭で鋭化

TABLE VI
汎化。選別器は NYUv2 で学習しており、深度モデルは全行で Marigold V2 である。適合率はいずれも同じ残存率 6% で測った。

| 評価データ | 選別なし | ＋選別器 | 適合率 |
|---|---|---|---|
| NYUv2（在ドメイン） | −1.90% | **+11.92%** | 50.2% |
| ScanNet | +3.26% | +2.81% | 17.4% |
| Hypersim | +2.28% | −4.64% | 55.8% |

すると +39.49% になる) ので、本手法は NYUv2 と同様に Hypersim の在ドメインでも働き、学習と利用でドメインが変わったときにだけ働かなくなる。

残る 3 通りの対処は失敗した。RGB チャネルを落とすと、転移はむしろ悪化した。ScanNet で残存率を 2% から 20% まで掃引しても、選別なしに届く設定は無かった。NYUv2 795 枚と Hypersim 795 枚を等量混合して学習すると、在ドメインの結果を損ない、転移も改善しなかった。データ量もこの差を説明しない。NYUv2 を 393 枚に削ると利得は 2.2 ポイント（+11.92% から +9.72%、seed 2 本）下がるが、在ドメインと ScanNet の差は 9.1 ポイントある。

モデル非依存な後処理が、それゆえにデータセット非依存であるとは限らない。

**適合率は 3 行を並べない。** NYUv2 で学習した選別器は、在ドメインよりも Hypersim で適合率が高い（50.2% に対し 55.8%）のに、結果はそこで最悪である。そもそも適合率はデータセットをまたいで比較できない。輪郭画素のうち真の段差に乗っている割合が異なり、NYUv2 の 6.07% に対し Hypersim は 22.8% である。3 行を分けているのは、評価データが選別器の学習ドメインと一致するかどうかであり、それを測れる量に還元することは著者らにはできていない。

**上限と適用範囲。** 第 III-D 節のオラクル選別は +43.39%、本手法は +11.92% であり、差は適合率にある（50.2% 対 100%）。AbsRel と $\delta_1$ の変化は改善と主張するには小さく、劣化していないことのみを主張する。教師と $BF_1$ はともに正解の深度段差を参照する。正解データは推論に現れないが、定義を共有している点は結果の解釈に影響しうる。

## VII. おわりに

境界がすでにある程度整った深度モデルでは、後処理の鋭化は大半のセグメンテーション輪郭が深度段差を伴わないために失敗する。修正操作を固定し、その適用対象のみを学習することで、利得の帰属が明確になり、再学習なしに深度モデル間で転移するが、データセット間では転移しない。選別を学習ドメインに依存しないものにすることが、主要な今後の課題である。

## 謝辞

本研究の実装・実験・執筆には、著者の指示のもとで Anthropic の Claude Code（Claude Opus モデル）を用いた。コードの大部分の作成、実験の実行と分析、全節の文章の起草と改訂、および図 1・図 2 を生成するスクリプトの作成は、この AI システムが行った。著者は研究を方向づけ、結果と本文を確認し、内容のすべてに責任を負う。

## References

[1] B. Ke, A. Obukhov, S. Huang, N. Metzger, R. C. Daudt, and K. Schindler, “Repurposing diffusion-based image generators for monocular depth estimation,” in *CVPR*, 2024.
[2] J. He, H. Li, W. Yin et al., “Lotus: Diffusion-based visual foundation model for high-quality dense prediction,” in *ICLR*, 2025.
[3] I. Pavlovic, T. Wandel, A. Obukhov, L. Bartolomei, A. Davydov, F. Tosi, M. Poggi, S. Süsstrunk, and D. Dai, “Marigold V2: Revisiting diffusion transformers for monocular depth estimation,” arXiv:2609.08084, 2026.
[4] G. M. Garcia, K. Knaebel, C. Schmidt, D. de Geus, A. Hermans, and B. Leibe, “Fine-tuning image-conditional diffusion models is easier than you think,” in *WACV*, 2025.
[5] A. Bochkovskii et al., “Depth Pro: Sharp monocular metric depth in less than a second,” in *ICLR*, 2025.
[6] F. Tosi, Y. Liao, C. Schmitt, and A. Geiger, “SMD-Nets: Stereo mixture density networks,” in *CVPR*, 2021.
[7] M. Ramamonjisoa, Y. Du, and V. Lepetit, “Predicting sharp and accurate occlusion boundaries in monocular depth estimation using displacement fields,” in *CVPR*, 2020.
[8] M. Ramamonjisoa and V. Lepetit, “SharpNet: Fast and accurate recovery of occluding contours in monocular depth estimation,” in *ICCV Workshops*, 2019.
[9] K.-S. Peng, G. Ditzler, and J. Rozenblit, “Edge-guided occlusion fading reduction for a light-weighted self-supervised monocular depth estimation,” arXiv:1911.11705, 2019.
[10] A. Muthukkumar, “Bayesian monocular depth refinement via neural radiance fields,” in *Proc. IEEE 8th Int. Conf. Algorithms, Computing and Artificial Intelligence (ACAI)*, 2025, pp. 488–492.
[11] A. Kirillov et al., “Segment Anything,” in *ICCV*, 2023.
[12] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, “Indoor segmentation and support inference from RGBD images,” in *ECCV*, 2012.
[13] A. Dai, A. X. Chang, M. Savva, M. Halber, T. Funkhouser, and M. Nießner, “ScanNet: Richly-annotated 3D reconstructions of indoor scenes,” in *CVPR*, 2017.
[14] M. Roberts et al., “Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding,” in *ICCV*, 2021.
[15] A. Geiger, P. Lenz, and R. Urtasun, “Are we ready for autonomous driving? The KITTI vision benchmark suite,” in *CVPR*, 2012.
[16] T. Schöps, J. L. Schönberger, S. Galliani, T. Sattler, K. Schindler, M. Pollefeys, and A. Geiger, “A multi-view stereo benchmark with high-resolution images and multi-camera videos,” in *CVPR*, 2017.
[17] I. Vasiljevic et al., “DIODE: A dense indoor and outdoor depth dataset,” arXiv:1908.00463, 2019.