拡散単眼深度推定における選択的な境界鋭化

TODO 著者名
TODO 専攻・学科
TODO 大学
TODO 市, 国
TODO メールアドレス

***Abstract*—拡散モデルに基づく単眼深度推定は滑らかな面の精度は高いが、深度の不連続（物体境界）がぼやけるという欠点がある。この欠点に対してセグメンテーションモデルが見つけた輪郭で予測深度を鋭化するのが自然な対処だが、すべての輪郭に鋭化を掛けると境界 BF_1 は悪化する。本研究では、この悪化が深度段差を伴わない輪郭への鋭化に起因することに着目し、鋭化操作は固定したまま、適用すべき輪郭のみを学習によって選別する手法を提案する。実際のデータを使った実験の結果、NYUv2 において提案手法は境界 BF_1 を 11.9% 改善し、同じ選別器を再学習なしにアーキテクチャと出力表現の異なる深度モデルへ適用しても 27.8% の改善を得た。**

***Index Terms*—単眼深度推定, 深度境界, セグメンテーション, 拡散モデル**

I. はじめに

近年、大規模な画像生成モデルが持つ事前知識を単眼深度推定に転用する研究が進んでいる。Marigold [1] は画像生成用の拡散モデル Stable Diffusion を合成 RGB-D データで微調整し、少量の学習データから高い汎化性能を持つ深度推定器を構築した。Lotus [2] はこれを発展させ、多段の拡散過程を 1 ステップの予測に置き換えることで、精度を保ったまま推論を大幅に高速化した。さらに Marigold V2 [3] は、画像編集用の拡散トランスフォーマを土台とすることで精度を一段と高めている。

一方で、これらの手法には物体境界における深度の不連続がぼやけるという課題がある。これは生成モデルが持つ滑らかさの事前知識や、解像度を落とした潜在空間上で予測を行う構造に起因すると考えられ、遮蔽境界の段差が数画素にわたってにじむことがある。この劣化は、画像全体を対象とした指標では、境界画素が画像のごく一部にすぎないため表に現れにくいが、境界専用の指標を使うことによって明らかになる [5]。

深度の不連続面がぼやけることに対処するために、境界を後処理によって改善する手法が提案されている。これらの手法は、深度モデルに手を加えずに済み、任意のモデルの出力に適用できる。先行研究は、遮蔽境界の周囲で画素を再配置する変位場の学習 [7] や、エッジを手がかりとする後処理 [9] など、深度をどう修正するかを学習してきた。

より単純な対処として、セグメンテーションの結果を手がかりにする方法が考えられる。Segment Anything [11] のようなセグメンテーションモデルは、画像を物体や領域ごとに切り分け、その輪郭を高い精度で抽出できる。物体の輪郭は多くの場合、深度が不連続に変わる位置と一致する。そこで、輪郭を境に予測深度を両側から埋め直し、ぼやけた段差を急峻にする（以下、鋭化と呼ぶ）。しかし Marigold V2 に対してすべての輪郭へ鋭化を適用すると、境界 BF_1 はかえって低下する。これはセグメンテーション輪郭の大半が壁紙の柄や床の目地のように、輪郭ではあっても深度段差を伴わないためである。このような輪郭に鋭化を適用すると、存在しない不連続を導入してしまう。

この結果は、鋭化の成否が輪郭の位置よりも、どの輪郭に適用するかで決まることを示唆している。実際、正解データを用いて深度段差上の輪郭のみを選ぶと、輪郭の位置を一切変えずに効果は改善に転じる。

そこで本研究では、鋭化操作は固定したまま、適用すべき輪郭のみを学習によって選別することで深度の不連続のぼやけを改善する手法を提案する。選別器は RGB 画像・予測深度・輪郭を入力とする小規模な U-Net であり、深度モデルとセグメンテーションモデルは変更しない。学習するのは選別器だけであるため、得られた改善を選別の学習に帰属させることができる。

本研究の貢献は次の 3 点である。

1) 鋭化操作を固定し、その適用対象の輪郭のみを学習によって選別する後処理手法を提案する。
2) 提案手法が、学習を伴わない手法や古典的な輪郭保存フィルタを上回り、境界精度を改善することを示す。
3) 提案手法が再学習なしに深度モデル間で転移する一方、データセット間では転移しないことを示す。

II. 関連研究

A. 拡散モデルに基づく単眼深度推定

Marigold [1] は画像生成用の拡散モデル Stable Diffusion を合成 RGB-D データで微調整し、アフィン不変な深度を推定する。Lotus [2] は、ノイズではなく深度そのものを予測させ、時刻を固定した 1 ステップの推論に置き換えることで、精度と速度をともに改善した。Garcia ら [4] は、Marigold の推論手順を修正したうえで 1 ステップの推論と end-to-end の微調整を組み合わせると、精度を保ったまま桁違いに高速化できることを示した。Marigold V2 [3] は画像編集用の拡散トランスフォーマを土台とし、アフィン不変な log 深度を 1 ステップで推定する。これらはいずれも深度推定モデル自体を改良する研究であり、本研究はモデルには手を加えず、その出力を後処理する点で異なる。

B. 深度境界の改善

Ramamonjisoa ら [7] は、遮蔽境界の周囲で画素を再配置する 2 次元の変位場を学習し、任意の深度推定器の出力を後処理で改善する。NYUv2 の学習 795 枚・評価 654 枚という設定も本研究と同じであり、最も近い先行研究である。SharpNet [8] は遮蔽輪郭の推定を深度ネットワークの学習に組み込み、Peng ら [9] は、自己教師あり単眼深度推定で生じる遮蔽境界付近の劣化を、エッジを手がかりとする後

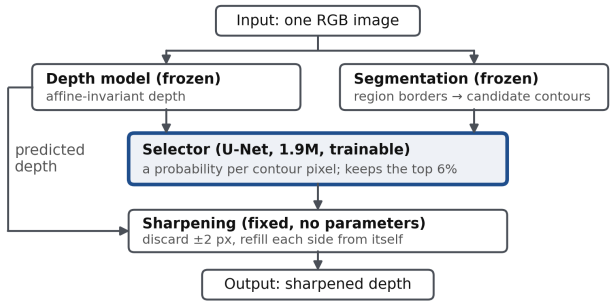


Fig. 1. 提案手法の流れ。入力の RGB 画像から、凍結した深度推定モデルが深度を、凍結したセグメンテーションモデルが候補となる輪郭を求める。選別器は画像・深度・輪郭から各輪郭画素が深度段差上にある確率を出し、確率の高い一定割合だけを残す。鋭化は残った輪郭でのみ適用され、その他の画素は変化しない。学習するのは選別器だけである。

処理で抑える。Muthukkumar [10] は、単眼推定と NeRF から得た深度を融合して細部を回復する。これらはいずれも深度の修正方法そのものを設計または学習する。本研究は修正操作を固定し、それをどこに適用するかだけを学習する。なお [7] は学習済み重みが公開されていないため、本稿では直接比較を行わない。

C. 深度推定とセグメンテーション

Segment Anything [11] は、物体の種類を指定せずに画像中の任意の領域を切り出せるセグメンテーションモデルである。本研究はその輪郭を深度境界の候補として用い、そのうち深度段差を伴うものを学習によって選別する。著者らの知る限り、セグメンテーションモデルの輪郭を深度境界の候補として用いる研究はない。

D. 境界の評価指標

正解深度に対する絶対誤差の比を平均した AbsRel や、予測と正解の比が 1.25 倍以内に収まる画素の割合 δ_1 のような画素平均の指標は、境界画素が画像のごく一部であるため、境界のぼやけをほとんど反映しない。Depth Pro [5] は、隣接画素間の深度の比が閾値を超える位置を深度段差とみなし、閾値を 5% から 25% まで掃引して、その一致を F1 で測るスケール不変な境界指標（BF_1）を提案した。SMD-Nets [6] はステレオ推定の評価のため、正解の境界画素における誤差を小さな位置ずれを許して測る Soft Edge Error（SEE）を提案しており、Marigold V2 [3] もこれを用いている。本研究はこの 2 つを用い、新しい指標は提案しない。

III. 手法

A. 概要

図 1 に提案手法の全体像を示す。入力は 1 枚の RGB 画像である。深度推定モデルがアフィン不変な深度を予測し、セグメンテーションモデルが領域の境界から候補となる輪郭を抽出する。選別器は、画像・予測深度・輪郭を入力として、各輪郭画素が実際の深度段差上にある確率を出し、確率の高い一定割合を残す。最後に、残された輪郭に第 III-B 節の障壁鋭化を適用する。学習するのは選別器だけで、深度推定モデルとセグメンテーションモデルは凍結し、障壁鋭化は学習するパラメータを持たない。

B. 障壁鋭化

拡散モデルに基づく深度推定器は、物体境界で前景と背景の深度を混ぜ合わせ、1 画素で切り替わるべき段差を数画素にわたる傾斜として出力する。境界の位置が分かっていれば、その周囲の混ざった画素を捨て、各側をその側の深度だけで埋め直すことで段差を鋭く戻せる。本研究は境界の位置をセグメンテーションモデルの輪郭から得て、輪郭を深度の内挿を遮る障壁として扱うことから、この操作を**障壁鋭化**と呼ぶ。

z を予測深度、V をその有効画素、$C \subseteq V$ を輪郭画素の集合とする。操作はまず帯

$$B = \{\, p \in V \mid \mathrm{dist}(p, C) \le r_b \,\} \tag{1}$$

を捨て、$V \setminus B$ の連結成分にラベルを付ける。これにより輪郭の両側は異なるラベルを持つ。次にラベルを 1 画素ずつ内側へ伝播させて B を覆い、各 $p \in B$ にラベル $\ell(p)$ を与える。捨てた各画素は、同じラベルを持つ帯の外の画素、すなわち輪郭の同じ側にある画素だけを使って埋め直す。

$$\hat{z}(p) = \frac{1}{|N(p)|} \sum_{q \in N(p)} z(q) \tag{2}$$

ここで $N(p) = \{\, q \notin B \mid \|q - p\| \le r_f,\ \ell(q) = \ell(p) \,\}$ である。B の外側の画素は変化しない。成分ラベルは輪郭そのものから作るのであって、セグメンテーションマスクからではない。設定値は帯の幅 r_b と埋め直しの半径 r_f の 2 つだけで、学習するものは何もない。$r_f > r_b$ である必要があり、さもなければ $N(p)$ が空になり、操作は深度マップを変更しない。

両側が分かれるのは、輪郭が閉じているか画像端に達している場合だけである。画像の内側で途切れる輪郭では、その先端を回り込んで有効領域がつながるため、そこでは帯の両側が同一の連結成分に属し、片側からの補間が成立しない。選別は輪郭画素の一部だけを残し、輪郭を全体の輪ではなく断片にするため、これが生じる箇所を増やす。いずれも修復を弱める性質であり、本稿のすべての数値にそのまま含まれている。

C. 選別器

選別器は、セグメンテーションモデルが抽出した輪郭のうち、深度段差を伴うものだけを残すためのネットワークである。各輪郭画素が実際の深度段差上にあるかどうかを判定する二値分類として学習し、推論時には確率の高い輪郭画素だけを障壁鋭化に渡す。

入力と出力。選別器は U-Net で、RGB 画像（3 チャネル）、予測深度（1）、輪郭マスク（1）を入力し、画素ごとに 1 つのロジットを出す。予測深度は画像ごとに標準化する。log 深度ではなく視差 v を出すモデルに対しては、先に $-\log \max(v, 10^{-3})$ を適用する。視差は深度が小さいほど大きくなるため、そのまま与えると符号の反転した信号を渡すことになり、またアフィン不変な視差は 0 以下にもなりうるので、下限でクリップする。この変換は近似であり、表 II の Lotus の結果にはその影響が含まれる。

残存率。確率の閾値ではなく、画像ごとに確率の高い順に輪郭画素の割合 ρ を残す。閾値を固定すると、場面に含まれる輪郭の量によって残す量が変わり、鋭化が使う予算

がフレームごとに動いてしまう。ρ は学習データにおける正例の割合に合わせる。

ラベルと損失。輪郭画素は、正解深度の不連続から 1 px 以内にあれば正例とする。ここで不連続とは、隣接画素の深度比が閾値 τ を超える段差である。選別器は、輪郭画素の上だけで平均した二値交差エントロピーで学習する。輪郭でない画素は選別の候補にならないためである。正解データはラベル生成にのみ用い、推論時には使用しない。

IV. 実験

A. 設定

NYUv2 [12] の評価用 654 枚で評価する。学習フレームとはシーンが重複しない。第 IV-E 節の転移先は、[3] が用いる ScanNet [13] の検証用 800 枚と、Hypersim [14] のシーン単位ホールドアウト 300 枚である。正解深度は各データセット固有の有効マスクと深度範囲で用い、NYUv2 のみ Eigen crop を併用する。指標は Depth Pro [5] のスケール不変な境界 BF_1 を用いる。各土台モデル自身の未鋭化の予測に対する BF_1 の相対変化を報告する。予測は採点前にそれぞれの空間（Marigold V2 は log 深度、Lotus は視差）で正解に整合させる。この整合はすべての変種に等しく作用する。

深度モデル。本研究は、この系統の中で可能な限り離れた 2 つのモデルで評価する。一つは Marigold V2（4 bit QLoRA で微調整された 213 億パラメータの拡散トランスフォーマ、アフィン不変な log 深度を出力）、もう一つは Lotus（8.68 億パラメータの UNet、視差を出力）である。いずれも NYUv2 の BF_1 を報告していないため、ベースラインは著者らが測定した。

ベンチマークの選択。BF_1 は隣接画素を比較するため、その両方が有効であるだけの密度を正解深度に要求する。土台モデルが評価される 5 つのベンチマークのうち 3 つはこれを満たさない。KITTI [15] は隣接ペアの 13.2%、ETH3D [16] は 4.1% しか有効でなく、DIODE [17] は密であるものの、評価プロトコルが本手法の対象である深度勾配を除外し、屋内の不連続の 99.4% が失われる。5 つのうち BF_1 が定義できるのは NYUv2 と ScanNet であり、本研究はその両方で評価した。加えて Hypersim でも評価するが、これは 5 つのうちの一つではなく、Marigold V2 自身の学習ドメインであり、第三の転移テストとして用いる。

手法の設定。障壁鋭化は $r_b = 2$、$r_f = 3$ とする。選別器は 4 段の U-Net で、パラメータ数は 193 万である。学習フレームでは輪郭画素の 6.066% が真の段差から 1 px 以内にあるため、残存率は $\rho = 6\%$ とする。不連続の閾値は $\tau = 10\%$ とし、評価集合ではなく検証集合で選んだ。学習用 795 枚から外した 40 シーン・141 枚で BF_1 を測ると、10% が $+12.74\%$ で、15・20・25% の $+8.66$・$+6.29$・$+5.28\%$ を上回る。閾値を上げると正例が輪郭画素の 6.07% から 2.13% まで減り、固定の予算がほとんど負例に費やされるためである。本手法のハイパーパラメータはすべて検証集合で決定した（第 IV-E 節の比較手法の一つは例外で、その旨を同節に記す）。NYUv2 の学習用 795 枚をシーン単位で分け、654 枚を学習、141 枚を検証に充て、検証集合で成績が最良のエポックを用いる。学習は RTX 4090 1 枚で 16 分・VRAM 3.5 GB を要する。

実装の詳細。選別器の学習には AdamW を用い、学習率 3×10^{-4}、weight decay 10^{-4}、コサインスケジュール、40 エポック、バッチサイズ 4 とした。フレームは 480×640 のまま用い、リサイズもデータ拡張も行わない。帯と充填半径は画素単位で定義されるため、尺度を変えると $r_b = 2$ の意味が変わるからである。輪郭は Segment Anything [11] の ViT-H チェックポイントを自動モードで用い、48×48 のプロンプト格子と既定の品質フィルタで生成した。第 IV-E 節の「grid 16」「grid 32」はこの格子を変えたものである。1 枚の輪郭集合は、得られた各マスクの幅 1 画素の境界の和であり、マスクそのものの和ではない。

TABLE I
MARIGOLD V2 で後処理による鋭化が失敗する理由と、何がそれを直すか。NYUv2 654 枚。オラクル選別は正解データを用いてセグメンテーション輪郭の部分集合を選ぶもので、輪郭は 1 画素も動かさない。

鋭化した輪郭	残存率	BF_1 の変化
セグメンテーションモデルの全輪郭	100%	-1.90%
オラクル選別（段差から 1 px 以内）	6.07%	$+$**43.39**%

B. 選別の必要性

NYUv2 で Segment Anything が描く輪郭すべてに障壁鋭化を適用すると、Marigold V2 の境界 BF_1 は 1.90% 低下する（表 I）。

真の深度不連続それぞれから最寄りの輪郭までの距離を測ると、中央値 1.00 px、66.9% が 1 px 以内、76.9% が 2 px 以内である。輪郭は境界のある場所にあるが、輪郭画素の 79.8% は、半径 8 画素の窓の中に深度段差を一つも持たない。これらは壁紙の柄、床の目地、ポスターの縁である。そこへ鋭化を適用すると、平坦な領域に誤った不連続を導入することになる。

79.8% は半径 8 画素の窓という緩い基準、以下の選別は 1 画素という厳しい基準である。1 枚あたり 22,167 画素あるセグメンテーション輪郭（有効画素の 10.6%）のうち、真の不連続から 1 px 以内にあるのは 1,345 画素、すなわち 6.07% である。それをちょうど残し、残した輪郭はすべて元の位置に置いたまま鋭化すると、効果は -1.90% から $+43.39\%$ へ動く（表 I）。したがって性能低下の主因は輪郭の位置精度ではなく、適用対象の選別にあると考えられる。第 III-C 節の選別器はこの選別を学習する。

C. 主結果

表 II は、アーキテクチャもパラメータ規模も出力表現も共有しない 2 つの深度モデルでの結果である。seed だけが異なる 4 つの選別器を、すべて Marigold V2 の予測で学習した。同じ 4 つを Lotus へ再学習なしで適用し、視差から log 深度への変換だけを加えている。Lotus 側の標準偏差は、その 4 つを Lotus に適用したときのばらつきであって、Lotus で学習した 4 モデルのばらつきではない。

第一のモデルでは seed 4 本すべてが $+10\%$ を超え、95% 信頼区間の下限は $+10.49\%$ である。画素単位の精度も劣化しない。AbsRel は 0.03881 から 0.03860 へ、δ_1 は 0.97969 から 0.98000 へと、いずれもわずかに良い方向に動いている。

フレーム単位で採点すると、平均が少数のフレームに支えられているのではないことが分かる。651 枚のうち 484 枚（74.3%）で改善し、相対利得の中央値は $+13.15\%$、第 1・第 3 四分位は -0.19% と $+31.57\%$ である。すなわち 4

TABLE II
主結果。SEED 4 本、± は標準偏差。同じ 4 つの選別器を両モデルに適用しており、学習は第一のモデルでのみ行った。絶対値では BF_1 が 0.0884 から 0.0989 へ、0.0693 から 0.0886 へ変化する。

土台の深度モデル	BF_1	選別なし	＋選別器
Marigold V2・213 億・log	0.0884	−1.90%	**+11.92 ± 0.90**%
Lotus・8.68 億・視差	0.0693	+10.31%	**+27.83 ± 1.27**%

TABLE III
SOFT EDGE ERROR。表 II の 4 SEED のうち +12.49% を出した 1 つ（4 本中 2 番目）を、両モデルにそのまま適用した値。小さいほど良く、% は各モデル自身のベースラインに対する相対変化。「GT 輪郭」は正解の不連続そのもので鋭化するもので、セグメンテーション輪郭から選んで到達できる上限ではない。表 I のオラクル選別はこれとは別の、はるかに小さい上限である。

	BF_1	SEE_3	SEE_5	SEE_7
Marigold V2				
ベースライン	0.0884	0.1148	0.0882	0.0758
＋選別器	+12.49%	−3.34%	−2.89%	−2.39%
移設	−0.50%	+0.32%	+0.46%	+0.52%
GT 輪郭	+209.8%	−11.44%	−5.09%	−2.91%
Lotus				
ベースライン	0.0693	0.1403	0.1147	0.1014
＋選別器	+28.18%	−5.18%	−5.54%	−5.48%
移設	−0.57%	+0.20%	+0.23%	+0.24%
GT 輪郭	+279.0%	−12.96%	−9.81%	−8.73%

枚に 1 枚はわずかに悪化している。ベースライン BF_1 が 0 の 3 枚は、相対利得が定義できないため除いている。

図 2 に、提案手法を適用したフレームの例を示す。これは AbsRel が中央値以下のフレームのうち、改善の大きい一例である。画像全体では、選別された輪郭の周囲の帯の外側は変化しない。椅子の下部を切り出した中段では、ベースラインが数画素にわたってぼかしている段差が、鋭化後には急峻になっている。下段の不連続エッジを比べると、椅子の縦の境界では、ベースラインで予測のみ（赤）や正解のみ（灰）に分かれていた画素が、鋭化後は正解と一致する画素（緑）になっている。

D. Soft Edge Error による評価

一つの指標でしか見えない改善は、その指標の定義による改善かもしれない。そこで Soft Edge Error [6] でも測った。Marigold V2 が採用している境界指標で、その実装から移植した。SEE_k は、正解の境界画素において、$k \times k$ 近傍のどれかの正解深度との絶対誤差の最小値を平均する。境界のズレは許し、にじみは罰する。BF_1 と違って深度単位の絶対誤差なのでスケール不変ではなく、採点前に整合させる必要がある。小さいほど良い。

2 つの指標は、両モデルのすべての変種で一致する。選別器は両方で改善、移設した場合は両方で悪化、GT 輪郭での鋭化は両方で最良。したがって**この改善は BF_1 の定義の産物ではない**。

E. 分析

本節では、得られた改善が何に由来し、どこまで成り立つかを分析する。まず、学習を伴わない手法と比べ、改善が学習した選別によるものであることを確かめる。次に、セグメンテーションモデルの寄与を測り、選別器を別のデータセットに適用したときの汎化を調べる。最後に、計算コストを示す。

TABLE IV
学習を伴わない手法。土台モデルごとに別々に測定した BF_1 の変化。移設の行は独立な 3 回の移設の平均、ランダム 2 行は 3 回の抽出の平均で、いずれも選別器と同じ 1 枚ごとの予算を使う。フィルタの行は GUIDED FILTER と JOINT BILATERAL FILTER を 4 通りの半径で試した最良値で、両モデルとも JOINT BILATERAL・半径 1 である。

手法	Marigold V2	Lotus
なし（全輪郭）	−1.90%	+10.31%
移設（同じ疎さ・違う場所）	−0.50%	−0.57%
画素ランダム	−24.96 ± 0.53%	−22.11 ± 1.17%
ブロックランダム	−1.04 ± 0.15%	−0.03 ± 0.36%
手作り特徴の閾値（最良）	+1.25%	+10.46%
joint bilateral filter, r=1	−4.75%	−7.15%
学習した選別器	**+11.92**%	**+27.83**%
学習の寄与	**10.7** pt	**17.4** pt

比較手法。利得は学習ではなく鋭化そのものから来ているのかもしれず、あるいは単に疎であることから来ているのかもしれない。表 IV は、学習を伴わない 6 つの代替手段を、各土台モデル自身の予測で測定したものである。

フィルタの行は古典的な代替手段である。画像を誘導画像とする guided filter ないし joint bilateral filter は、深度の境界を画像のエッジへ寄せる標準的な方法である。いずれも両モデルで悪化し、しかも半径について単調に悪化する（最も緩い設定で −4.75%・−7.15%、最も強い設定で −50.14%・−45.30%）。フィルタは平滑化しかできず、平滑化された境界は BF_1 が減点する対象そのものである。

手作り特徴による比較手法は、予測深度の log 勾配の局所的な記述子に閾値を掛けるものである。その特徴量は、ホールドアウトでの順位付けの良さではなく test 集合の最終指標で選んだ。これは本手法が持たない優位を比較手法に与えるので、比較は保守的になる。

ランダム 2 行は、選別器の出力から 1 枚ごとに取った同じ予算をちょうど使う。画素ランダムが両モデルで近い値（−24.96% と −22.11%）を示すのは、この比較手法が測っているのが鋭化操作の性質であって深度モデルの性質ではないからである。輪郭を連続させたままのブロックランダムは、どちらでもほとんど損をせず、Lotus では誤差の範囲で 0 である。画素ランダムをあれほど破壊的にしているのは選択を散らすことであり、選び方が悪いこと自体の代償はほとんど無い。

セグメンテーションモデルの寄与。セグメンテーションモデルを完全に外し、選別器が RGB と深度から自力で境界を見つけ、有効画素すべてを候補とする設定では +7.30% となる。このアブレーションは両方とも単一 seed の値なので、比較すべきはその seed の +12.49% である。セグメンテーションモデルの寄与は 5.19 ポイント、その実行の 42% にあたる。この寄与は適合率ではなく再現率の側から生じている。セグメンテーション輪郭上で数えると真の段差は 1 枚あたり 1,345 画素で、予算 1,330 画素はその 98.9% を覆える。有効画素全体で数えると 2,941 画素あり、同じ予算では再現率の上限が 45.2% になる。セグメンテーションモデルは正解の集合を絞ることによって寄与している。

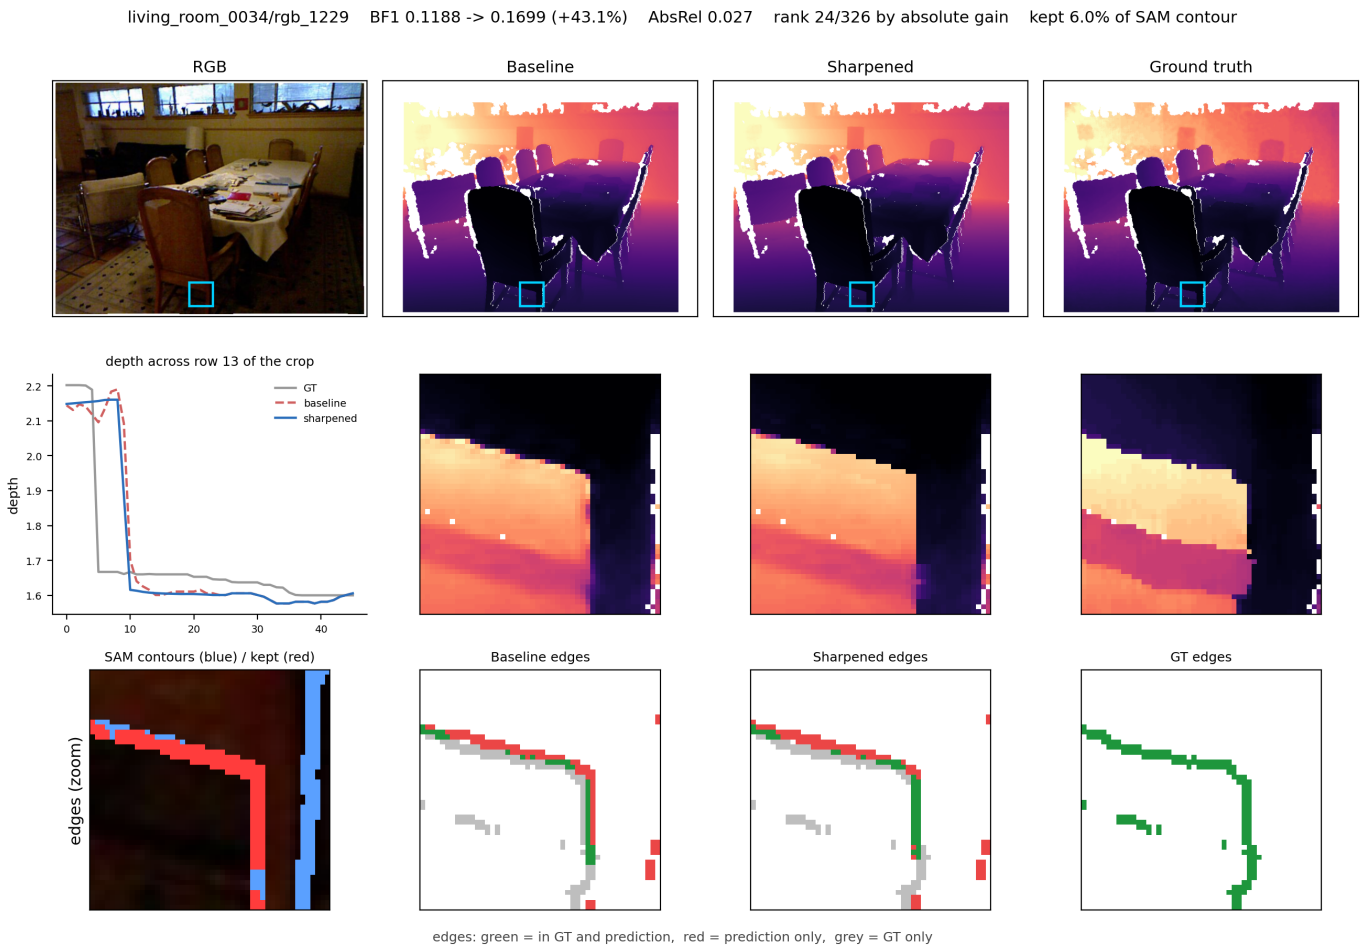


Fig. 2. リビングルームのフレームにおける提案手法の適用例。上段は画像全体、中段は水色の枠で示した 48 px の切り出しとその断面の深度プロファイルで、3 枚は切り出し範囲から求めた共通のカラースケールで表示している。下段はセグメンテーション輪郭（青）と選別器が残した輪郭（赤）、および各深度マップの不連続エッジである。エッジの緑は正解と予測の両方、赤は予測のみ、灰は正解のみ。

TABLE V
汎化。選別器は NYUv2 で学習しており、深度モデルは全行で MARIGOLD V2 である。

評価データ	選別なし	＋選別器
NYUv2（在ドメイン）	−1.90%	**+11.92%**
ScanNet	+3.26%	+2.81%
Hypersim	+2.28%	−4.64%

データセット間の汎化。本手法は深度モデルをまたいでは転移するが、データセットをまたいでは転移しない。表 V は、NYUv2 で学習した選別器を ScanNet と Hypersim に適用した結果である（深度モデルは全行で Marigold V2）。

いずれの未見データセットでも、選別器は全輪郭を使う場合に及ばない。以下に示すように、これはデータセット自体の性質ではなく、学習ドメインと評価ドメインの不一致に起因すると考えられる。Hypersim 10,000 枚で学習した選別器は、Hypersim 自身では +5.05% に達する（選別なしは +2.28%、適合率 88.1%、正例率 22.8%）。同じチェックポイントは NYUv2 で −2.23%、ScanNet で +0.39% である。Hypersim も飽和していない (自身の GT 輪郭で鋭化すると +39.49% になる) ので、本手法は NYUv2 と同様に Hypersim の在ドメインでも働き、学習と利用でドメインが変わったときにだけ働かなくなる。

残る 3 通りの対処は失敗した。RGB チャネルを落とすと、転移はむしろ悪化した。ScanNet で残存率を 2% から 20% まで掃引しても、選別なしに届く設定は無かった。NYUv2 795 枚と Hypersim 795 枚を等量混合して学習すると、在ドメインの結果を損ない、転移も改善しなかった。データ量もこの差を説明しない。NYUv2 を 393 枚に削ると利得は 2.2 ポイント（+11.92% から +9.72%、seed 2 本）下がるが、在ドメインと ScanNet の差は 9.1 ポイントある。

計算コスト。表 VI は RTX 4090 1 枚での 1 フレームあたりの実時間である。ウォームアップ後に実フレームで測定した。

選別器は 12.0 ms、鋭化は 18.3 ms であり、本研究が追加するのは 30.3 ms、深度推定モデル自身の 495 ms の 6% である。それ以外をすべて支配するのはセグメンテーションモデルで、点グリッドに応じて 534 ms から 2,603 ms を要する。

点グリッドの粗さ。grid 16 は grid 48 の利得の 92% を、セグメンテーションのコストの 20% で達成する。差の 0.90

TABLE VI
1 枚あたりの処理時間と、得られる改善量。GRID 16 と 48 は表 II の 4 SEED の平均と標準偏差、他の 2 行はそこで +12.49% を出した単一 SEED の値である。大きな影響を持つ設定はセグメンテーションモデルの点グリッドのみである。

構成	ms/枚	BF_1 の変化	1 pt あたり
深度推定モデルのみ	495	—	—
＋選別器・SAM なし	525	+7.30%	**72**
＋選別器・grid 16	**1,059**	**+11.02 ± 0.64**%	**96**
＋選別器・grid 32	1,996	+11.17%	179
＋選別器・grid 48	3,128	+11.92 ± 0.90%	262

ポイントは seed 間の標準偏差と等しく、1 組の実行では順序を決められない。ただし seed で対応をとると grid 48 が 4 本すべてで上回り、差は 0.90 ± 0.29 ポイント（対応のある t 検定、$p = 0.009$）である。差は一貫しており、かつ小さい。

V. おわりに

本研究では、拡散モデルに基づく単眼深度推定器が物体境界をぼかす問題に対し、深度モデルに手を加えない後処理手法を提案した。本手法は、セグメンテーションモデルの輪郭で深度の段差を鋭く戻す障壁鋭化を固定の操作とし、それを適用する輪郭だけを小さな U-Net で選別する。

実験から次の 3 点が分かった。第一に、すべての輪郭に鋭化を適用すると境界精度はかえって低下する。その原因は輪郭の位置精度ではなく、深度段差を伴わない輪郭まで鋭化することにある。第二に、適用する輪郭を学習によって選別すると、NYUv2 において Marigold V2 の境界 BF_1 が 11.9% 改善し、同じ選別器を再学習なしで Lotus に適用すると 27.8% 改善した。この改善は学習を伴わない手法や古典的なフィルタでは得られず、Soft Edge Error でも確認された。第三に、選別器は深度モデルをまたいでは転移するが、データセットをまたいでは転移しない。

限界。第 IV-B 節のオラクル選別は +43.39%、本手法は +11.92% であり、その差は選別の適合率にある（50.2% 対 100%）。AbsRel と δ_1 については、劣化しないことのみを主張する。教師と BF_1 はともに正解の深度段差を参照する。正解データは推論に現れないが、定義を共有している点は結果の解釈に影響しうる。選別を学習ドメインに依存しないものにすることが、主要な今後の課題である。

謝辞

本研究では、コードの実装、および初期草稿の作成に Anthropic の Claude Code を使用した。その後、著者が全体を精査しており、内容の責任は著者が負う。

REFERENCES

[1] B. Ke, A. Obukhov, S. Huang, N. Metzger, R. C. Daudt, and K. Schindler, “Repurposing diffusion-based image generators for monocular depth estimation,” in *CVPR*, 2024.
[2] J. He, H. Li, W. Yin et al., “Lotus: Diffusion-based visual foundation model for high-quality dense prediction,” in *ICLR*, 2025.
[3] I. Pavlovic, T. Wandel, A. Obukhov, L. Bartolomei, A. Davydov, F. Tosi, M. Poggi, S. Süsstrunk, and D. Dai, “Marigold V2: Revisiting diffusion transformers for monocular depth estimation,” arXiv:2609.08084, 2026.
[4] G. M. Garcia, K. Knaebel, C. Schmidt, D. de Geus, A. Hermans, and B. Leibe, “Fine-tuning image-conditional diffusion models is easier than you think,” in *WACV*, 2025.
[5] A. Bochkovskii et al., “Depth Pro: Sharp monocular metric depth in less than a second,” in *ICLR*, 2025.
[6] F. Tosi, Y. Liao, C. Schmitt, and A. Geiger, “SMD-Nets: Stereo mixture density networks,” in *CVPR*, 2021.
[7] M. Ramamonjisoa, Y. Du, and V. Lepetit, “Predicting sharp and accurate occlusion boundaries in monocular depth estimation using displacement fields,” in *CVPR*, 2020.
[8] M. Ramamonjisoa and V. Lepetit, “SharpNet: Fast and accurate recovery of occluding contours in monocular depth estimation,” in *ICCV Workshops*, 2019.
[9] K.-S. Peng, G. Ditzler, and J. Rozenblit, “Edge-guided occlusion fading reduction for a light-weighted self-supervised monocular depth estimation,” arXiv:1911.11705, 2019.
[10] A. Muthukkumar, “Bayesian monocular depth refinement via neural radiance fields,” in *Proc. IEEE 8th Int. Conf. Algorithms, Computing and Artificial Intelligence (ACAI)*, 2025, pp. 488–492.
[11] A. Kirillov et al., “Segment Anything,” in *ICCV*, 2023.
[12] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, “Indoor segmentation and support inference from RGBD images,” in *ECCV*, 2012.
[13] A. Dai, A. X. Chang, M. Savva, M. Halber, T. Funkhouser, and M. Nießner, “ScanNet: Richly-annotated 3D reconstructions of indoor scenes,” in *CVPR*, 2017.
[14] M. Roberts et al., “Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding,” in *ICCV*, 2021.
[15] A. Geiger, P. Lenz, and R. Urtasun, “Are we ready for autonomous driving? The KITTI vision benchmark suite,” in *CVPR*, 2012.
[16] T. Schöps, J. L. Schönberger, S. Galliani, T. Sattler, K. Schindler, M. Pollefeys, and A. Geiger, “A multi-view stereo benchmark with high-resolution images and multi-camera videos,” in *CVPR*, 2017.
[17] I. Vasiljevic et al., “DIODE: A dense indoor and outdoor depth dataset,” arXiv:1908.00463, 2019.